인공지능수학 (2026-1)

2. 텍스트 데이터의 표현 (2)

국립금오공과대학교 컴퓨터공학부

컴퓨터공학전공 / 인공지능공학전공

김 경 수

목차

I. 텍스트 데이터의 분석

II. 텍스트 데이터의 시각화

학습목표

① 텍스트 내에 내재된 정보를 요약하여 표현하는 다양한 방법을 이해하고 이를 실습을 통하여 확인할 수 있다.

Ⅰ. 텍스트 데이터의 분석

문장에서 주제어 찾기

(1) 문장에서 주제어 찾기

① 빈도수 벡터에 의한 주제어 선정

댓글 A

마스크를 착용하고 개인위생을 청결하게 하는 것이 효과적인 예방법입니다. 마스크 착용이 가장 효과적이니 마스크를 반드시 착용하세요. 나머지 단어들 : 불용어

댓글 B

뭐니뭐니해도 마스크 착용이 가장 효과적입니다.
마스크를 꼭 착용하고 개인위생을 청결하게 합시다.

↓ 핵심 단어에 대한 빈도수

핵심 단어	마스크	착용	개인위행	청결	효과적	예방법	반드시
댓글 A	3	3	1	1	1	1	1
댓글 B	2	2	1	1	1	0	0

7차원임

문장에서 주제어 찾기

앞의 표에서 댓글 A와 B에 나타난 핵심 단어의 빈도수 벡터를 $\boldsymbol{a}, \boldsymbol{b}$라고 하면, 전체 핵심 단어의 개수가 7이므로 다음과 같이 표현할 수 있다.

$$\boldsymbol{a} = (3, 3, 1, 1, 1, 1, 1)$$
$$\boldsymbol{b} = (2, 2, 1, 1, 1, 0, 0)$$

→ 댓글 A에서 가장 중요한 주제어는 '마스크'와 '착용' :

'마스크'와 '착용'이 각각 3번 사용

→ 댓글 B에서 가장 중요한 주제어는 '마스크'와 '착용' :

'마스크'와 '착용'이 각각 2번 사용

문장에서 주제어 찾기

② 상대도수(Relative Frequency)에 의한 주제어 선정

- 댓글 A와 B에서 '마스크'와 '착용'이 각각 3번과 2번 사용되었기 때문에 댓글 A에서 '마스크'와 '착용'이 댓글 B보다 더 중요하다고 생각할 수 있는가?

  → 절대적인 빈도수가 더 큰 값을 가지면 더 중요한 단어라고 판정할 수 있는가?

  → 이러한 문제점을 보완하기 위해 **상대도수(relative frequency)**가 활용됨.

여기서 잠깐! 상대도수(상대빈도)

도수는 빈도수와 같은 의미를 나타내는 용어이며 상대도수는 상대빈도라고도 부른다.
상대도수는 도수의 총합에 대한 각 계급(Class)의 도수를 비율로 나타낸 것이며, 각 계급의 상대도수는 다음과 같이 표현된다.

$$\text{어떤 계급의 상대도수} = \frac{\text{해당 계급의 도수}}{\text{도수의 총합}}$$

각 계급의 상대도수를 표로 나타낸 것을 상대도수 분포표라고 부른다.

문장에서 주제어 찾기

- 핵심 단어에 대한 상대도수 분포표의 작성과 분석

핵심 단어	마스크	착용	개인위생	청결	효과적	예방법	반드시	총합
댓글 A	3	3	1	1	1	1	1	11
상대도수	3/11	3/11	1/11	1/11	1/11	1/11	1/11	1
댓글 B	2	2	1	1	1	0	0	7
상대도수	2/7	2/7	1/7	1/7	1/7	0	0	1

➢ 위의 상대도수 분포표를 이용하여 댓글 A와 B에 대한 상대도수 벡터를 각각 $\tilde{a}$와 $\tilde{b}$라고 하면 다음과 같이 표현할 수 있다.

댓글 A : $\tilde{a}$=(3/11, 3/11, 1/11, 1/11, 1/11, 1/11, 1/11)

댓글 B : $\tilde{b}$=(2/7, 2/7, 1/7, 1/7, 1/7, 0, 0)

3/11 (= 0.27) < 2/7 (= 0.29)

'마스크'와 '착용'은 댓글 B에서 더 큰 비중을 갖는다

문장에서 주제어 찾기

예제 2.9 다음에 나타낸 표는 세 문장 A, B, C에서 핵심 단어에 대한 빈도수를 나타낸 것이다. 물음에 답하라.

핵심 단어	수출	경제	무역	적자	경제성장률
문장 A	5	2	2	0	1
문장 B	2	1	4	3	0
문장 C	4	1	0	0	1

(1) 상대도수 분포표를 작성하고 세 문장 A, B, C에 대한 상대도수 벡터 $\tilde{a}, \tilde{b}, \tilde{c}$ 를 각각 구하라.

(2) 주어진 세 문장 중에서 '수출' 단어에 대한 비중이 가장 큰 문장을 찾아라.

문장에서 주제어 찾기

풀이

(1) 주어진 표를 이용하여 상대도수 분포표를 작성하면 다음과 같다.

핵심 단어	수출	경제	무역	적자	경제성장률	총합
문장 A	5	2	2	0	1	10
상대도수	5/10	2/10	2/10	0	1/10	1
문장 B	2	1	4	3	0	10
상대도수	2/10	1/10	4/10	3/10	0	1
문장 C	4	1	0	0	1	6
상대도수	4/6	1/6	0	0	1/6	1

위의 상대도수 분포표를 이용하여 각 문장에 대한 상대도수 벡터를 $\tilde{a}, \tilde{b}, \tilde{c}$ 라고 하면 다음과 같다.

댓글 A : $\tilde{a} = (5/10, 2/10, 2/10, 0, 1/10)$

댓글 B : $\tilde{b} = (2/10, 1/10, 4/10, 3/10, 0)$

댓글 C : $\tilde{c} = (4/6, 1/6, 0, 0, 1/6)$

(2) 세 문장에서 '수출' 단어에 대한 상대도수는 5/10=0.5, 2/10=0.2, 4/6=0.67이므로 문장 C에서 '수출' 단어의 비중이 가장 크다는 것을 알 수 있다.

단어 임베딩 벡터의 정의

- **특정 단어를 빈도수 벡터 또는 원-핫 벡터 표현할 때 발생하는 문제점**
  - ➢ 텍스트 데이터에서 전체 단어의 개수가 커지면 벡터의 차원도 커지기 때문에 벡터를 저장하기 위한 메모리 공간도 증가하게 된다.
  - ➢ 단어의 의미와 단어들 간의 유사도를 알기 어렵다.
- **이를 해결하기 위해 단어 임베딩 벡터가 널리 활용된다.**

단어 임베딩 벡터의 정의

- **단어 임베딩 벡터(Word Embedding Vector)**
  - 벡터의 차원을 전체 핵심 단어의 개수로 설정하지 않고 사용자가 설정한 값으로 모든 단어의 벡터차원을 맞춘다. 이 과정에서 벡터의 성분이 0과 1의 값만 가지는 것이 아니라 실수값을 가지게 된다. → **밀집벡터(Dense Vector) 표현**
  - **단어 임베딩(Word Embedding)** : 단어를 밀집벡터 형태로 표현하는 것을 의미하며, 최종 표현 결과를 **임베딩 벡터(Embedding Vector)**라고 부른다.
  - **임베딩 방법** : LSA, Word2Vec, Fast Text, Glove 등 나중에 배울듯
  - 단어 임베딩 벡터는 단어를 벡터로 표현할 때, 의미 정보도 함께 표현할 수 있도록 해주는 방법이다.

    유사한 의미일수록 벡터 공간에서 가깝고
    반대되는 의미일수록 벡터 공간에서 멀다(반대 방향으로)

벡터의 연산과 스칼라 곱

① **벡터의 덧셈** : 벡터의 덧셈은 대응하는 성분들을 합한 것으로 정의

$$\boldsymbol{a} = (a_1, a_2), \boldsymbol{b} = (b_1, b_2)$$

$$\boldsymbol{a} + \boldsymbol{b} \triangleq (a_1 + b_1, a_2 + b_2)$$

$$\boldsymbol{a} = (a_1, a_2 \cdots, a_n), \quad \boldsymbol{b} = (b_1, b_2, \cdots, b_n)$$

$$\boldsymbol{a} + \boldsymbol{b} \triangleq (a_1 + b_1, a_2 + b_2, \cdots, a_n + b_n)$$

- **벡터의 덧셈에 대한 기하학적인 의미**

ⓐ $\boldsymbol{a} + \boldsymbol{b}$는 $\boldsymbol{a}$와 $\boldsymbol{b}$가 이루는 평행사변형의 대각선을 연결하는 벡터이다.

→ **평행사변형의 법칙**

ⓑ 평행사변형의 법칙에서 벡터 $\boldsymbol{a}$를 마주보는 변으로 평행이동시키면 **삼각형의 법칙**이 얻어진다.

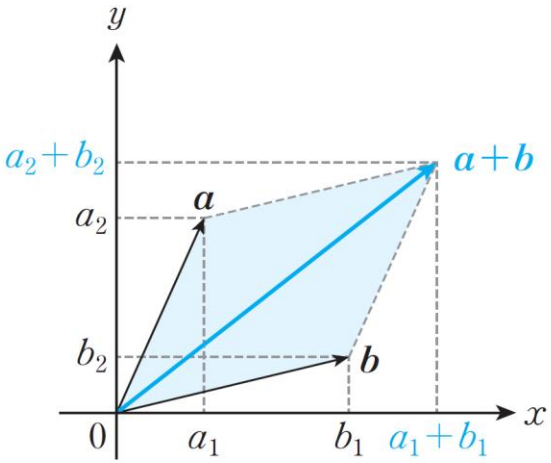

[그림 2.15] 벡터의 덧셈

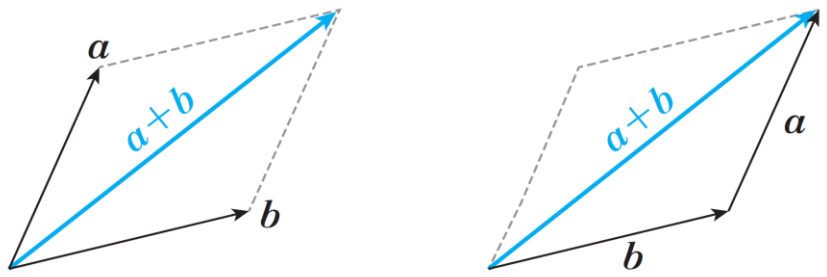

(a) 평행사변형의 법칙 (b) 삼각형의 법칙

[그림 2.16] 벡터 덧셈의 두 가지 법칙

벡터의 연산과 스칼라 곱

② **벡터의 뺄셈** : 두 벡터의 뺄셈은 대응하는 성분들의 차로 정의

$$\boldsymbol{a} = (a_1, a_2), \boldsymbol{b} = (b_1, b_2)$$

$$\boldsymbol{a} + \boldsymbol{b} \triangleq (a_1 - b_1, a_2 - b_2)$$

→ **두 벡터의 뺄셈은 대응하는 성분들을 뺀 것으로 정의한다.**

- **벡터의 뺄셈에 대한 기하학적인 의미**

두 벡터 $\boldsymbol{a}$와 $\boldsymbol{b}$의 뺄셈은 두 벡터의 종점을 연결하면 되는데, $\boldsymbol{a} - \boldsymbol{b}$는 벡터 방향이 $\boldsymbol{a}$를 향하게 하고, $\boldsymbol{b} - \boldsymbol{a}$는 벡터 방향이 $\boldsymbol{b}$를 향하게 한다.

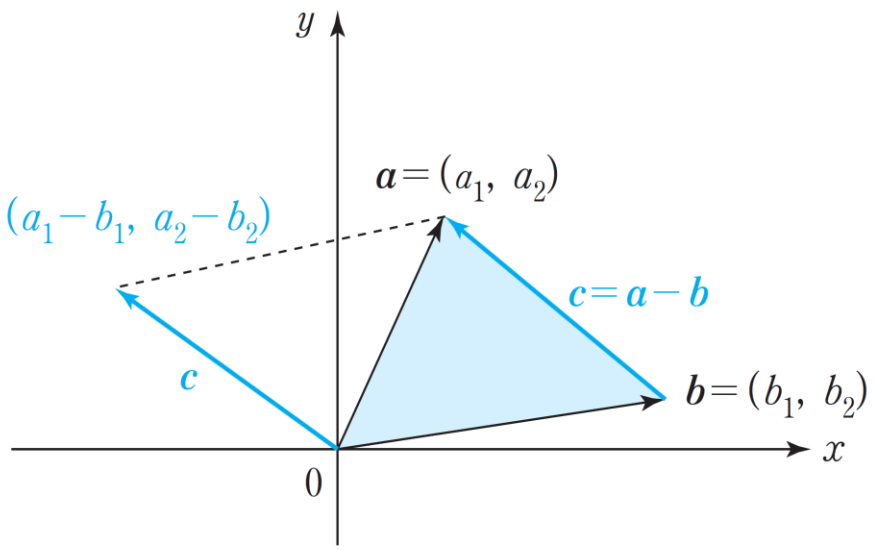

[그림 2.17] 벡터의 뺄셈

벡터의 연산과 스칼라 곱

- 크기와 방향이 같은 두 벡터의 뺄셈은 **영벡터(Zero Vector)**가 되며, 영벡터는 **모든 성분이 0인 벡터**로 정의한다.

$$\mathbf{0} = (0,0) \text{ 또는 } \mathbf{0} = (0,0,0)$$

- n차원 벡터에 대한 벡터 뺄셈

$$\boldsymbol{a} = (a_1, a_2, \cdots, a_n), \quad \boldsymbol{b} = (b_1, b_2, \cdots, b_n)$$

$$\boldsymbol{a} - \boldsymbol{b} \triangleq (a_1 - b_1, \ a_2 - b_2, \ \cdots, \ a_n - b_n)$$

벡터의 연산과 스칼라 곱

③ **스칼라 곱 :** $\boldsymbol{ka}$는 $\boldsymbol{a}$의 각 성분에 스칼라 k를 곱한 것으로 정의

$$\boldsymbol{a} = (a_1, a_2)$$

$$k\boldsymbol{a} \triangleq (ka_1, ka_2)$$

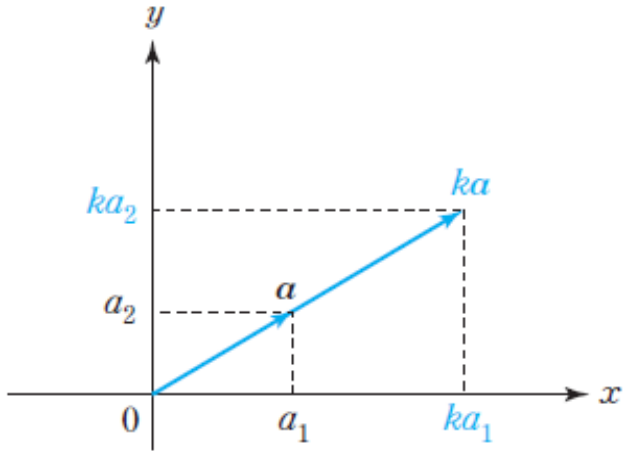

[그림 2.18] 벡터의 스칼라 곱

- **n차원 벡터에 대한 스칼라 곱**

$$\boldsymbol{a} = (a_1, a_2, \cdots, a_n) \longrightarrow k\boldsymbol{a} = (ka_1, ka_2, \cdots, ka_n)$$

- **스칼라 곱에 대한 기하학적인 의미**
  - 스칼라 k의 값에 따라 $k\boldsymbol{a}$는 **$\boldsymbol{a}$를 늘이거나 줄이는 것을 의미**하며, k가 음수인 경우 $k\boldsymbol{a}$는 주어진 벡터 $\boldsymbol{a}$와 방향이 반대이다.

벡터의 연산과 스칼라 곱

예제 2.11 공간벡터 $\boldsymbol{a}=(0,\ 2,\ 0)$, $\boldsymbol{b}=(-1,\ 0,\ 1)$, $\boldsymbol{c}=(1,\ -1,\ 1)$에 대하여 다음 물음에 답하라.

(1) $\boldsymbol{a}+\boldsymbol{b}-2\boldsymbol{c}$와 $3\boldsymbol{a}-4\boldsymbol{c}$를 계산하고 그 크기를 각각 구하라.

(2) 임의의 공간벡터 $\boldsymbol{d}=(1,\ 2,\ 3)$에 대하여 다음을 만족하는 k_1, k_2, k_3를 구하라.

$$k_1\boldsymbol{a}+k_2\boldsymbol{b}+k_3\boldsymbol{c}=\boldsymbol{d}$$

벡터의 연산과 스칼라 곱

풀이

(1) $\boldsymbol{a}+\boldsymbol{b}-2\boldsymbol{c}=(0,\ 2,\ 0)+(-1,\ 0,\ 1)-2(1,\ -1,\ 1)$

$$\therefore\ \boldsymbol{a}+\boldsymbol{b}-2\boldsymbol{c}=(-3,\ 4,\ -1)$$

$3\boldsymbol{a}-4\boldsymbol{c}=3(0,\ 2,\ 0)-4(1,\ -1,\ 1)$

$$\therefore\ 3\boldsymbol{a}-4\boldsymbol{c}=(-4,\ 10,\ -4)$$

$\|\boldsymbol{a}+\boldsymbol{b}-2\boldsymbol{c}\|=\sqrt{(-3)^2+4^2+(-1)^2}=\sqrt{26}$

$\|3\boldsymbol{a}-4\boldsymbol{c}\|=\sqrt{(-4)^2+10^2+(-4)^2}=\sqrt{132}$

(2) $k_1\boldsymbol{a}+k_2\boldsymbol{b}+k_3\boldsymbol{c}=\boldsymbol{d}$ 로부터 다음의 관계를 얻을 수 있다.

$(0,\ 2k_1,\ 0)+(-k_2,\ 0,\ k_2)+(k_3,\ -k_3,\ k_3)=(1,\ 2,\ 3)$

$$(-k_2+k_3,\ 2k_1-k_3,\ k_2+k_3)=(1,\ 2,\ 3)$$

$$-k_2+k_3=1,\ 2k_1-k_3=2,\ k_2+k_3=3$$

$$\therefore\ k_1=2,\ k_2=1,\ k_3=2$$

벡터의 연산과 스칼라 곱

예제 2.12

다음 그림에서 벡터 $\overrightarrow{AC}$ 와 $\overrightarrow{CM}$ 을 벡터 $\boldsymbol{a}$와 $\boldsymbol{b}$로 나타내어라. 단, M은 A와 B의 중점이고 $\overrightarrow{AB}=\boldsymbol{a}$, $\overrightarrow{BC}=\boldsymbol{b}$이다.

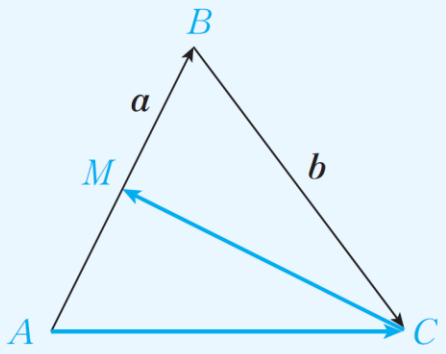

풀이

$\overrightarrow{AC}$ 는 삼각형의 법칙에 의하여 $\overrightarrow{AC}=\overrightarrow{AB}+\overrightarrow{BC}=\boldsymbol{a}+\boldsymbol{b}$이다.
삼각형의 법칙에 의하여 다음의 관계를 얻을 수 있다.

$$\overrightarrow{CM}+\overrightarrow{MA}=\overrightarrow{CA}$$

$$\therefore\ \overrightarrow{CM}=\overrightarrow{CA}-\overrightarrow{MA}=-\overrightarrow{AC}+\overrightarrow{AM}$$

$$=-(\boldsymbol{a}+\boldsymbol{b})+\frac{1}{2}\boldsymbol{a}=-\frac{1}{2}\boldsymbol{a}-\boldsymbol{b}$$

문장과 단어 사이의 유사도 판정

- **산술평균벡터의 정의**
  - 임베딩 벡터에서 정의되는 **산술평균 벡터**의 개념은 일반 수리통계에서 정의하는 평균의 개념과 동일한 형태로 정의할 수 있다.

정의 2.2 **산술평균벡터**

어떤 주어진 문장 S에 포함된 모든 단어들에 대한 임베딩 벡터가 $\boldsymbol{a}_1, \boldsymbol{a}_2, \cdots, \boldsymbol{a}_n$ 이라 할 때 임베딩 벡터들의 산술평균벡터 $\boldsymbol{a}$는 다음과 같이 정의된다.

$$\boldsymbol{a} \triangleq \frac{\boldsymbol{a}_1 + \boldsymbol{a}_2 + \cdots + \boldsymbol{a}_n}{n} = \frac{1}{n}\sum_{k=1}^{n} \boldsymbol{a}_k \tag{26}$$

이때 산술평균벡터 $\boldsymbol{a}$는 문장 $S = \{\boldsymbol{a}_1, \boldsymbol{a}_2, \cdots, \boldsymbol{a}_n\}$을 대표하는 벡터라고 부른다.

문장과 단어 사이의 유사도 판정

- **유사도(Similarity) 및 거리(Distance) 판정 과정**

  ⓐ 두 문장 A와 B에 대한 임베딩 벡터가 다음과 같다고 가정하자.

문장 A	화력	원자력	태양광
임베딩 벡터	$\boldsymbol{a}_1 = \overrightarrow{OA_1} = (0.6, 0.8)$	$\boldsymbol{a}_2 = \overrightarrow{OA_2} = (1.5, 0.5)$	$\boldsymbol{a}_3 = \overrightarrow{OA_3} = (1.2, 0.8)$

문장 B	콜라	마켓	열량
임베딩 벡터	$\boldsymbol{b}_1 = \overrightarrow{OB_1} = (0.6, 1.8)$	$\boldsymbol{b}_2 = \overrightarrow{OB_2} = (1.4, 1.6)$	$\boldsymbol{b}_3 = \overrightarrow{OB_3} = (1.6, 0.8)$

문장과 단어 사이의 유사도 판정

ⓑ 이 때, 산술평균벡터 $\boldsymbol{a}$와 $\boldsymbol{b}$를 계산하면 다음과 같다.

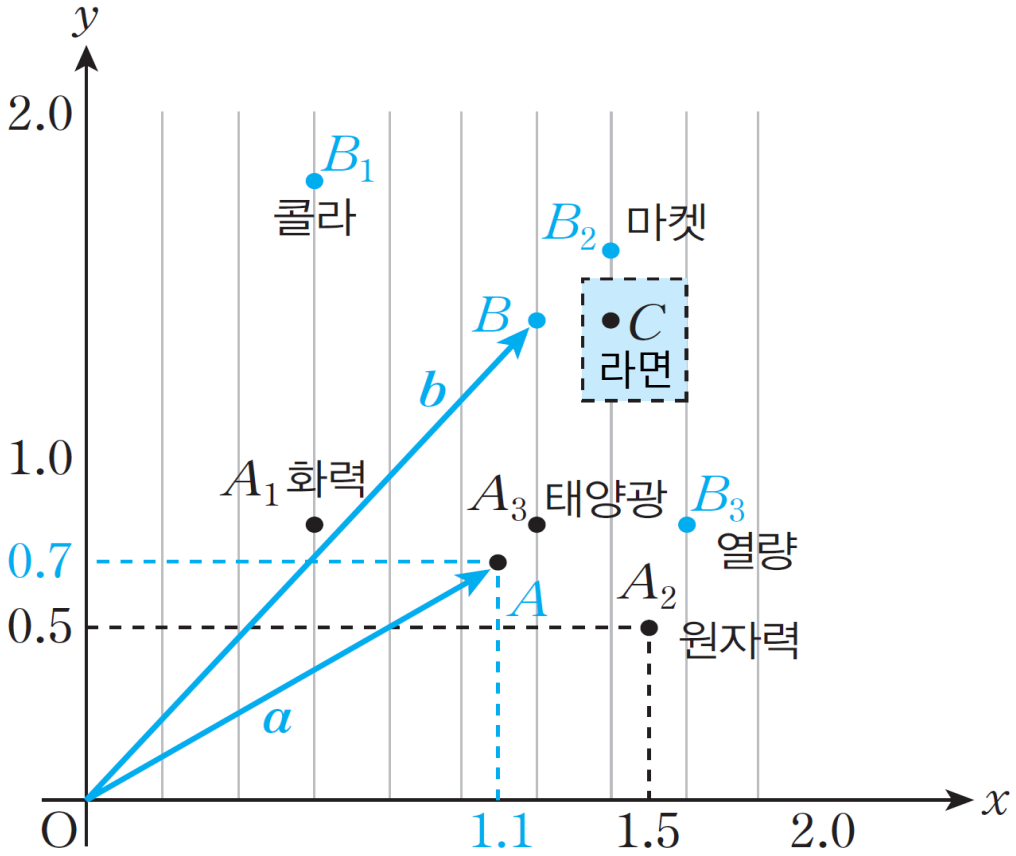

[그림 2.19] 임베딩 벡터와 산술평균벡터

문장 A	화력	원자력	태양광
임베딩 벡터	$\boldsymbol{a}_1=\overrightarrow{OA_1}=(0.6, 0.8)$	$\boldsymbol{a}_2=\overrightarrow{OA_2}=(1.5, 0.5)$	$\boldsymbol{a}_3=\overrightarrow{OA_3}=(1.2, 0.8)$

문장 B	콜라	마켓	열량
임베딩 벡터	$\boldsymbol{b}_1=\overrightarrow{OB_1}=(0.6, 1.8)$	$\boldsymbol{b}_2=\overrightarrow{OB_2}=(1.4, 1.6)$	$\boldsymbol{b}_3=\overrightarrow{OB_3}=(1.6, 0.8)$

$$\boldsymbol{a}=\frac{1}{3}(\boldsymbol{a}_1+\boldsymbol{a}_2+\boldsymbol{a}_3)=\left(\frac{0.6+1.5+1.2}{3}, \frac{0.8+0.5+0.8}{3}\right)=(1.1, 0.7)$$

$$\boldsymbol{b}=\frac{1}{3}(\boldsymbol{b}_1+\boldsymbol{b}_2+\boldsymbol{b}_3)=\left(\frac{0.6+1.4+1.6}{3}, \frac{1.8+1.6+0.8}{3}\right)=(1.2, 1.4)$$

문장과 단어 사이의 유사도 판정

ⓒ 새로운 단어 '라면'에 대한 임베딩 벡터가 $\boldsymbol{c} = [1.4, 1.4]$로 주어질 때, 두 산술평균벡터($\boldsymbol{a} = [1.1, 0.7]$, $\boldsymbol{b} = [1.2, 1.4]$)와 벡터 $\boldsymbol{c}$의 거리를 아래와 같이 계산할 수 있다.

낮은 거리 = 유사도 높음
먼 거리 = 유사도 낮음

$$\boldsymbol{c} = \overrightarrow{OC} = (1.4, 1.4)$$

$$\overline{CA} = \sqrt{(1.4-1.1)^2 + (1.4-0.7)^2} = 0.76$$

$$\overline{CB} = \sqrt{(1.4-1.2)^2 + (1.4-1.4)^2} = 0.2$$

→ $\overline{CA} > \overline{CB}$이므로, 단어 "라면"은 문장 B에 더 가까운 것으로 판정할 수 있다.

문장과 단어 사이의 유사도 판정

- **문장과 단어 사이의 유사도 판정 절차 요약**

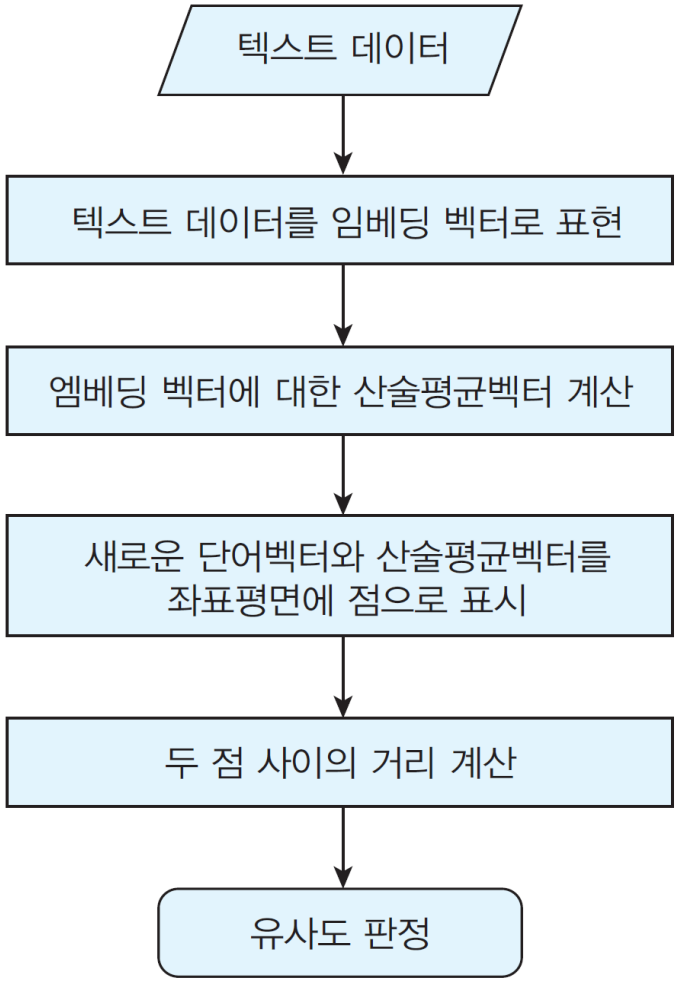

[그림 2.20] 문장과 단어 사이의 유사도 판정 절차

문장과 단어 사이의 유사도 판정

예제 2.13

다음 표는 두 문장 A와 B의 단어를 각각 임베딩 벡터로 나타낸 것이다. 만일 새로운 단어 '복숭아'에 대한 임베딩 벡터 $\boldsymbol{c} = \overrightarrow{OC} = (1.3, 1.5)$일 때, 단어 '복숭아'는 두 문장 중에서 어떤 문장에 더 가까운지를 판정하라. → B

문장 A	비스켓	케익	쿠기
임베딩 벡터	$\boldsymbol{a}_1 = \overrightarrow{OA_1} = (0.6, 0.9)$	$\boldsymbol{a}_2 = \overrightarrow{OA_2} = (1.3, 0.5)$	$\boldsymbol{a}_3 = \overrightarrow{OA_3} = (1.1, 1.0)$

문장 B	사과	배	포도
임베딩 벡터	$\boldsymbol{b}_1 = \overrightarrow{OB_1} = (0.8, 1.6)$	$\boldsymbol{b}_2 = \overrightarrow{OB_2} = (1.3, 1.5)$	$\boldsymbol{b}_3 = \overrightarrow{OB_3} = (1.5, 0.8)$

1.0, 0.8 0.3, 0.3

1.2 1.3 → 0.1 0.2

문장과 단어 사이의 유사도 판정

풀이

문장 A와 B를 대표하는 산술평균벡터를 각각 $\boldsymbol{a}$와 $\boldsymbol{b}$라고 하면 식(26)으로부터 다음과 같이 계산된다.

$$\boldsymbol{a}=\frac{1}{3}(\boldsymbol{a}_1+\boldsymbol{a}_2+\boldsymbol{a}_3)=\left(\frac{0.6+1.3+1.1}{3},\ \frac{0.9+0.5+1.0}{3}\right)=(1.0,\ 0.8)$$
$$\boldsymbol{b}=\frac{1}{3}(\boldsymbol{b}_1+\boldsymbol{b}_2+\boldsymbol{b}_3)=\left(\frac{0.8+1.3+1.5}{3},\ \frac{1.6+1.5+0.8}{3}\right)=(1.2,\ 1.3)$$

문제에서 단어 '복숭아'에 대한 임베딩 벡터가 $\boldsymbol{c}=\overrightarrow{OC}=(1.3, 1.5)$로 주어져 있으므로 점 $C(1.3, 1.5)$에서 점 $A(1.0, 0.8)$와 점 $B(1.2, 1.3)$ 사이의 거리를 구하면 다음과 같다.

$$\overline{CA}=\sqrt{(1.3-1.0)^2+(1.5-0.8)^2}=0.76$$
$$\overline{CB}=\sqrt{(1.3-1.2)^2+(1.5-1.3)^2}=0.22$$

단어 '복숭아'를 나타내는 벡터 $\boldsymbol{c}=(1.3, 1.5)$는 B와 거리가 더 가까우므로, 단어 '복숭아'는 문장 B와 더 유사하다.

Ⅱ. 텍스트 데이터의 시각화

텍스트 데이터의 시각화

- 텍스트 데이터를 수치나 수학기호로 표현하여 데이터의 내용이나 경향성 등을 분석하기 위하여 **시각화(Visualization)**하는 것이 편리하다.

→ 표, 산점도, 히스토그램, 워드 클라우드 등

① 표(Table)와 산점도

〈표 2.3〉 학생들의 신장과 체중

이름	번호	신장(cm)	체중(kg)
김○○	1	165	68
이○○	2	175	66
박○○	3	168	63
서○○	4	170	64
최○○	5	179	60
전○○	6	170	65
김△△	7	172	63
박△△	8	177	70

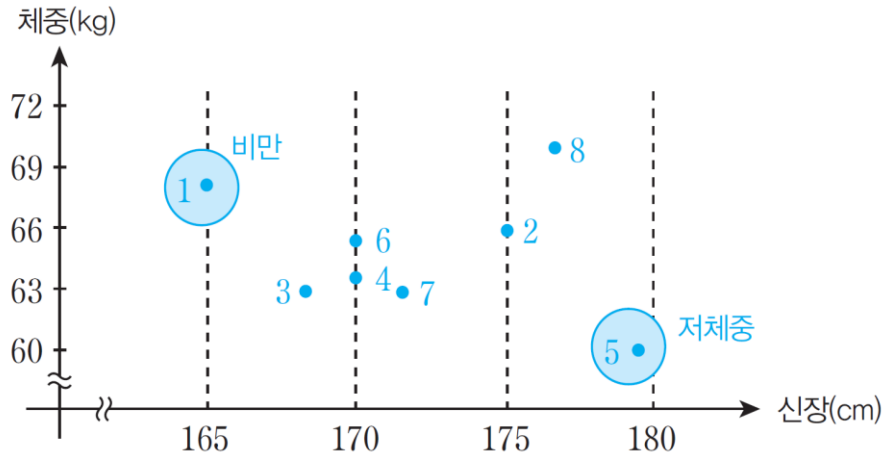

[그림 2.21] 신장과 체중에 대한 산점도

텍스트 데이터의 시각화

여기서 잠깐! 산점도(Scatter Plot)

변수 x와 y의 관계를 살펴보기 위하여 x와 y를 좌표축으로 하는 좌표평면 위에 순서쌍 (x, y)를 표시하여 도식화한 것을 산점도라고 부른다.

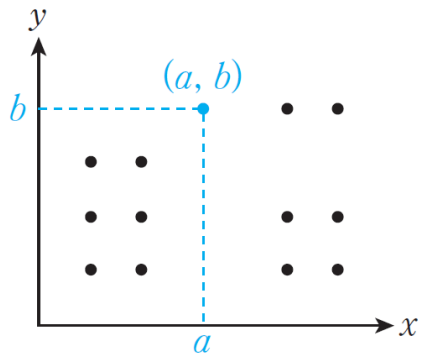

예를 들어 $x=a$이고 $y=b$일 때 순서쌍 (a, b)를 좌표평면에 나타내었다. 산점도는 2개의 수치형 변수간의 관계를 표현할 때 많이 사용되는 시각화 차트(Chart)이다.

- 산점도는 두 종류의 데이터를 2차원 좌표평면에 순서쌍(점)으로 표현하기 때문에 데이터의 분포를 파악하기 용이하다.

텍스트 데이터의 시각화

여기서 잠깐! 히스토그램(Histogram)

히스토그램은 표로 표현되어 있는 도수분포표를 그래프로 나타낸 것이며, 보통 가로축은 계급(Class), 세로축은 도수(Frequency)로 하여 그래프를 그리지만 필요에 따라 반대로 그리기도 한다.

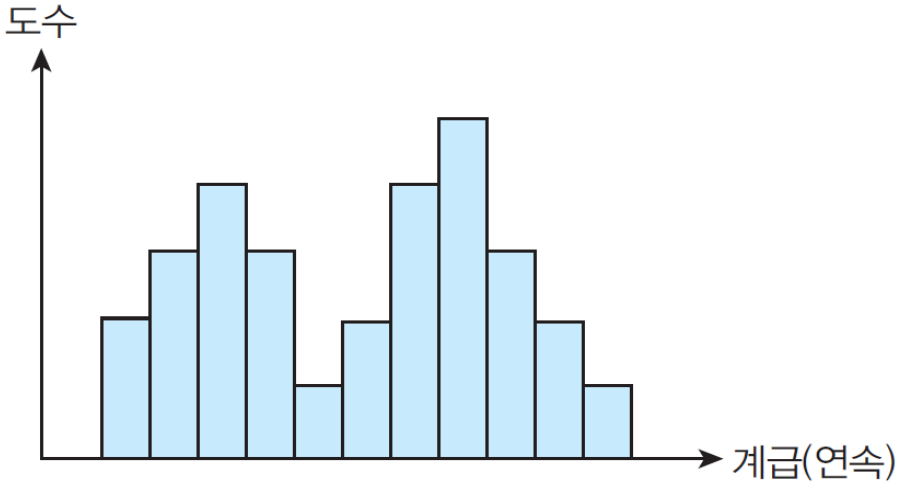

텍스트 데이터의 시각화

히스토그램은 각 계급에 속하는 데이터의 수가 많고 적음을 한 눈에 알아보기 쉽다는 장점이 있지만 계급이 연속적인 값을 가지는 경우에만 사용할 수 있다. 히스토그램과 유사한 막대그래프(Bar Graph)는 계급이 불연속일 때, 수량이 많고 적음을 비교하는 경우 사용하는 그래프이다. 막대그래프는 계급이 불연속이므로 막대간에 간격이 존재한다.

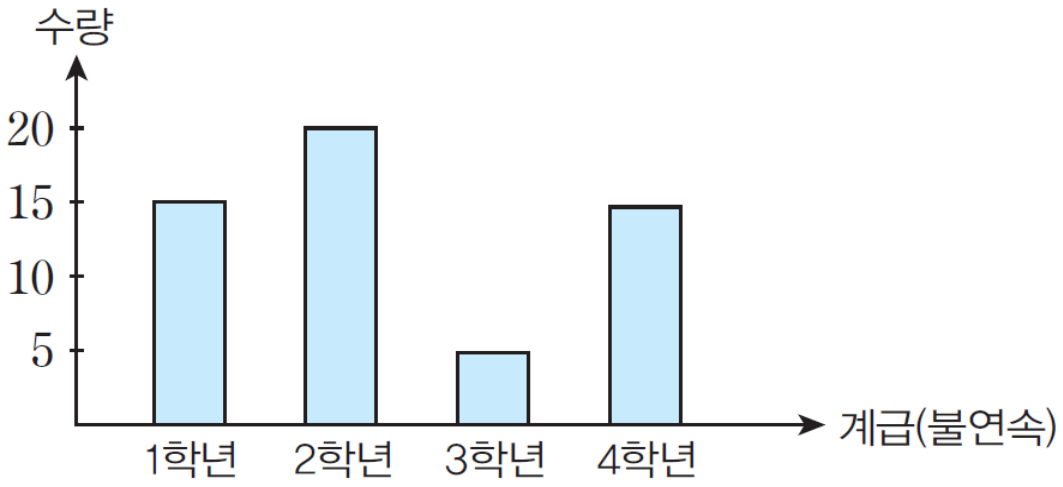

텍스트 데이터의 시각화

② 파이차트와 막대그래프

- 파이차트(Pie Chart)는 원 그래프라고도 하며, 전체에 대한 각 부분의 비율을 백분율로 산출하여 부채꼴 모양으로 나타낸 것이다.

  → 각 부채꼴의 중심각이 전체에서 차지하는 비율을 나타내므로 각 항목들의 비율을 한눈에 파악 가능

- 상대도수 분포표를 막대그래프와 파이차트로 시각화하여 표현할 수 있다.

단어	크기	벡터	성분	데이터	학생
상대도수	0.1	0.2	0.1	0.2	0.4

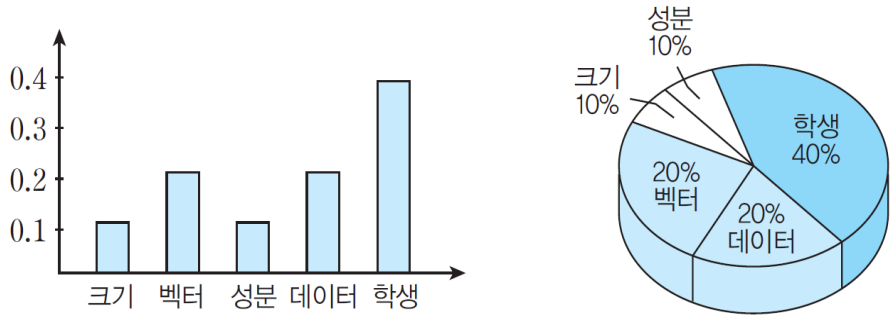

(a) 막대그래프 (b) 파이차트

[그림 2.22] 파이차트와 막대그래프

텍스트 데이터의 시각화

예제 2.14

다음은 5명의 학생들에 대한 기말고사 성적과 총점을 표로 나타낸 것이다. 물음에 답하라.

이름	국어	영어	수학	총점
김○○	80	80	60	220
홍○○	80	70	70	220
박○○	70	90	90	250
최○○	90	80	90	260
이○○	100	90	60	250

(1) 학생들의 국어와 영어 성적에 대한 산점도를 그려라.

(2) 학생들의 영어와 수학 성적에 대한 산점도를 그려라

(3) 각 학생들에 대한 총점을 막대그래프로 나타내어라.

풀이

(1) 국어 성적을 x축, 영어 성적을 y축으로 선정하여 산점도를 그리면 다음과 같다.

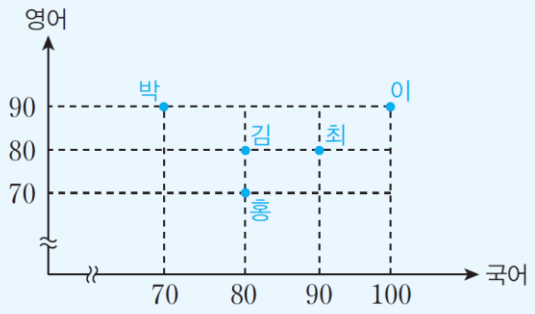

(2) 영어 성적을 x축, 수학 성적을 y축으로 선정하여 산점도를 그리면 다음과 같다.

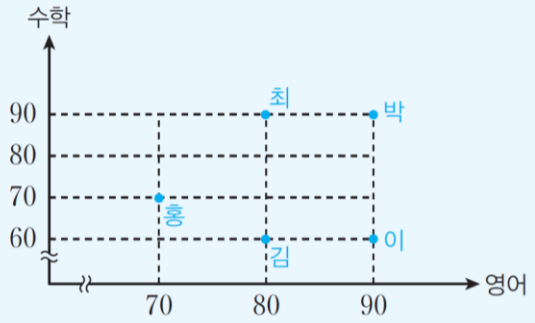

텍스트 데이터의 시각화

③ 워드 클라우드

- 워드 클라우드(Word cloud)는 문서에 사용된 단어의 중요도나 인기도 등을 고려하여 구름처럼 늘어 놓아 표시하는 시각화 유형의 하나이다.
  - **[예제]** 2026년 3월 18일 국제 분야 뉴스 내용 중 일부를 워드 클라우드로 표현한 결과

https://wordcloud.kr 에서 직접 워드 클라우드를 생성해보자.

텍스트 데이터의 시각화 실습

- **Google Colab을 이용한 파이썬 워드 클라우드 생성 실습**
  - 실습용 Colab notebook 파일: LMS에 업로드(**워드클라우드실습.ipynb**)
  - Colab notebook 파일의 각 셀을 실행시키면 아래와 같이 변수 "**example_sen**"에 주어진 문장에 대한 워드 클라우드가 생성되는 것을 확인할 수 있다.

```python
# 단어 빈도 계산
freq = Counter(words)

# 워드클라우드 생성
wc = WordCloud(
    width=1000,
    height=600,
    background_color="white",
    font_path=font_path,   # 한글이면 폰트 경로 지정 필요
    max_words=200
).generate_from_frequencies(freq)

# 워드클라우드 이미지 파일 저장
# (output_path에 워드클라우드 이미지 파일이 저장될 경로와 파일 이름 기입)
# wc.to_file(output_path)

# 워드 클라우드 이미지를 화면에 표시
plt.figure(figsize=(10, 6))
plt.imshow(wc, interpolation="bilinear")
plt.axis("off")
```

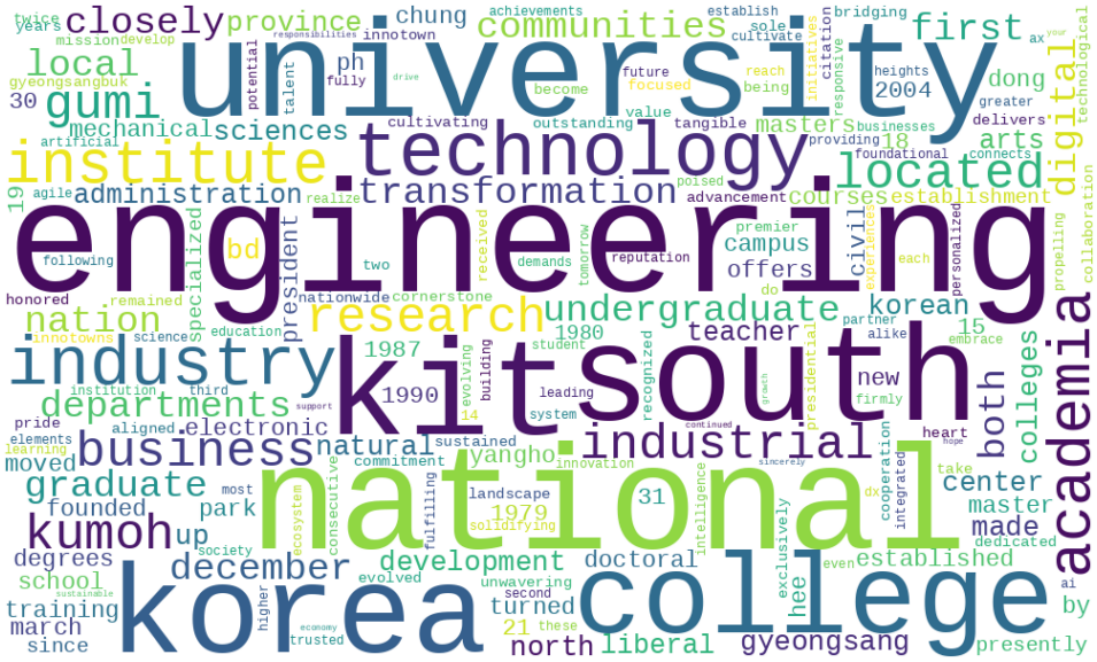

텍스트 데이터의 시각화 실습

- **확인할 사항**
  - 코드 내에서 텍스트 문장의 내용과 워드 클라우드 출력 결과를 비교
  - 워드 클라우드로부터 확인할 수 있는 본 문장의 핵심 단어는 무엇인가?
  - 소스코드의 전체적인 구조와 각 라인의 의미, **`wordcloud`** 라이브러리의 사용법 확인

- **추가적으로 실습해 볼 내용**
  - 불용어(stop word) 리스트를 수정했을 때 워드 클라우드가 어떻게 변화되는지 확인
  - 다른 문장(영어)으로 변경했을 때, 워드 클라우드가 어떻게 출력되는지 확인
  - 워드 클라우드 이미지 사이즈를 변경했을 때 이미지가 어떻게 출력되는지 확인
  - Google Colab이 아닌 로컬(local) 컴퓨터에서 실습하고, 텍스트 문서(.txt 파일)를 읽어서 워드 클라우드를 생성하는 기능으로 변경하기

Q & A