인공지능수학 (2026-1)

5. 유사도 분석과 텍스트 데이터의 분류

국립금오공과대학교 컴퓨터공학부

컴퓨터공학전공 / 인공지능공학전공

김 경 수

목차

I. 텍스트 데이터 분류의 기본 개념
II. 두 벡터 사이의 거리
III. 코사인 유사도
IV. 상관 계수

Ⅰ. 텍스트 데이터 분류의 기본 개념

4/27중간고사
D128호 예정 - 객관식, 단답형

분류(Classification)와 군집화(Clustering)

- **분류(Classification)**
  - ➢ 주어진 데이터(텍스트 또는 이미지)를 이미 알려진 범주 중 하나로 할당하는 작업
    =사전에 정해져있다
  - ➢ "텍스트 감성 분석"은 가장 대표적인 텍스트 분류 응용(application) 중 하나

    (※ 텍스트 뿐만 아니라 이미지, 영상 데이터에 대한 감성 분석도 가능)
  - ➢ 분류는 **지도 학습(Supervised learning)**의 대표적인 문제
    =감독학습
- **군집화(클러스터링, Clustering)**
  - ➢ 주어진 데이터 전체를 유사도 분석을 이용해서 몇 개의 그룹(Cluster)으로 묶는 방법
    , 분포 특성
  - ➢ 군집화는 **비지도학습(Unsupervised learning)**의 대표적인 문제
    = 비감독학습

텍스트 문서 분류의 응용 분야

- 스팸 메일 분류
- 문서의 종류 분류
- 감성 분석 (Sentiment analysis)
  - ➢ 사람들의 개별적인 의견, 성향, 태도와 같이 주관적인 정보가 다수 포함된 텍스트 데이터를 분석하여, 해당 텍스트 데이터가 어떤 감정 정보를 포함하는지 판단하는 기술
  - ➢ 예를 들어, 카톡 메시지를 분석하여 긍정(Positive), 부정(Negative), 중립(Neutral) 중 어떤 감정에 가장 가까운지 분석하는 기능

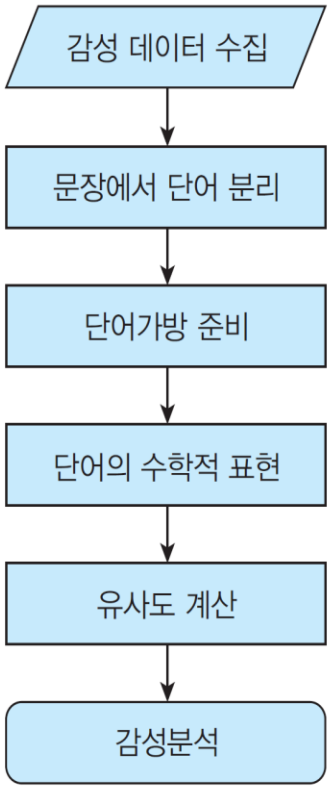

[그림 3.2] 감성분석 절차에 대한 순서도

텍스트 문서 분류의 응용 분야

- **텍스트 분류의 예: 스팸 메일 분류기**
  - ➢범주(Category): 스팸 메일, 정상 메일
    =클래스 라고도 한다
  - ➢데이터(Data): 각 범주별로 대표 이메일 문서들이 저장되어 있음
  - ➢입력(Input): 임의의 이메일 문서
  - ➢분류(Classification) : 주어진 이메일이 어떤 범주의 문서들과 가장 유사한지 유사도를 분석하여 유사도가 가장 높은 범주(스팸 or 정상)로 할당한다.

텍스트 문서 분류의 절차

- 주어진 문서에 대한 전처리 작업 수행
- 분석 대상 문서들에 포함된 모든 단어들을 **BOW**에 추가
  bag of words
- BOW에 추가된 단어들을 바탕으로, 각 문서를 벡터로 표현
  - 문서 d를 벡터로 표현하면 ➔ $\boldsymbol{d} = [d_1, d_2, \ldots, d_i, \ldots, d_n]^T$
  - 이때, 벡터 $\boldsymbol{d}$ 의 i번째 성분 d_i 는 BOW내 i번째 단어에 대한 TF-IDF Score.
- 문서들 간의 유사도를 계산하여 문서를 분류
- 문서 분류를 위해 필요한 수학적 개념
  - 텍스트 문서를 집합 또는 벡터로 표현
  - **임의의 두 집합 또는 벡터 간의 유사도를 측정하는 방법**

BOW (Bag of Word)

- 주어진 문장을 구성하는 단어들을 문맥이나 순서를 무시하고 하나의 집합으로 포함시킨 개념
- BOW에 포함된 각 단어들이 텍스트 문서를 분석하는데 핵심적으로 사용되는 단어로, 각 문서 내에서 해당 단어들이 등장하는 횟수를 이용하여 주어진 문서를 벡터로 표현할 수 있음

  TF-IDF
- 단, BOW를 생성하는 과정에서 문장 내 단어의 위치(순서)는 고려하지 않으므로 의미 정보가 무시되는 단점이 있음

텍스트 문서 간 유사도 측정의 개념

- 새로운 텍스트 문서 D_N이 주어질 때, N개의 문서 $D_1, \ldots D_N$ 중에서 어떤 문서와 가장 유사한가를 계산한다.
- 이를 위해 각 문서를 단어들의 **집합(set)** 또는 TF-IDF와 같은 **벡터(vector)**로 표현한다.
- 그렇다면, **집합 간 유사도** 또는 **벡터 간 유사도 측정**을 통해 문서 간의 유사도를 확인할 수 있다.

$\overrightarrow{D_N}$

$Sim(\overrightarrow{D_N}, \overrightarrow{D_1})$

$Sim(\overrightarrow{D_N}, \overrightarrow{D_2})$

$Sim(\overrightarrow{D_N}, \overrightarrow{D_3})$

$Sim(\overrightarrow{D_N}, \overrightarrow{D_4})$

$$\overrightarrow{D_1} = [0.301,\ 0,\ 0,\ 0,\ 0,\ 0.151,\ 0,\ 0]$$

$$\overrightarrow{D_2} = [0,\ 0.0417,\ 0,\ 0,\ 0,\ 0,\ 0.0417,\ 0.201]$$

$$\overrightarrow{D_3} = [0,\ 0.0417,\ 0,\ 0,\ 0,\ 0.100,\ 0.0417,\ 0]$$

$$\overrightarrow{D_4} = [0,\ 0.0209,\ 0.100,\ 0.100,\ 0.100,\ 0,\ 0.0417,\ 0]$$

★ **분류 알고리즘을 구현하기 위해서는 두 벡터 또는 집합 간의 유사도를 계산할 수 있어야 한다.**

유사도 측정 방법의 종류

- **두 집합 간의 유사도**를 측정하는 방법
  - 자카드 유사도 (Jaccard similarity)
- **두 벡터 간의 거리**를 이용하여 유사도를 측정하는 방법
  - 유클리드 거리 (Euclidean distance)
  - 맨하탄 거리 (Manhattan distance)
- **두 벡터 간의 사이각** 또는 **분포**를 이용하여 유사도를 측정하는 방법
  - 코사인 유사도 (Cosine similarity)
  - 피어슨 상관 계수 (Pearson correlation coefficient)
  - 마할라노비스 거리 (Mahalanobis distance)

4/2

Ⅱ. 두 집합 사이의 유사도

두 집합의 유사도를 측정하는 원리

- 두 집합 간의 유사도를 측정하는 원리
  - ➢ 두 집합의 교집합과 합집합을 분석한다.
  - ➢ 두 집합의 교집합과 합집합이 동일하다 ➔ 두 집합은 유사도가 1이다.
  - ➢ 두 집합의 교집합이 공집합이다 ➔ 두 집합은 유사도가 0이다.

- 따라서, 두 집합의 합집합의 원소들과 교집합의 원소들이 서로 얼마나 겹치는가를 분석하면, 두 집합 간의 유사도를 측정할 수 있다.

두 집합의 유사도를 측정하는 원리

- 자카드 유사도 (Jaccard Similarity)
  - ➢ 두 집합 A와 B의 합집합의 원소 개수와 교집합 원소 개수의 비율로 유사도를 측정

$$J(A,B) = \frac{n(A \cap B)}{n(A \cup B)}$$

$$= \frac{n(A \cap B)}{n(A) + n(B) - n(A \cap B)}$$

× 자카드(Paul Jaccard, 1868~1944)
스위스의 식물학자로 식물 사이의 유사도를 정리하기 위해 '자카드 유사도'를 고안하였다.

자카드(Jaccard) 유사도

- 자카드 유사도의 공식 분석

$$J(A,B) = \frac{n(A \cap B)}{n(A \cup B)} = \frac{n(A \cap B)}{n(A) + n(B) - n(A \cap B)}$$

  - 두 집합 A와 B의 합집합의 원소 개수와 교집합의 원소 개수의 비율
  - A : 집합 A에 포함된 원소의 집합
  - B : 집합 B에 포함된 원소의 집합
  - 분모: 두 집합 A와 B의 합집합 내 원소의 개수
  - 분자: 두 집합 A와 B의 교집합 내 원소의 개수
  - $J(A,B)$ 결과값의 유효 범위: 0 ~ 1

자카드(Jaccard) 유사도 활용 예제 (1)

- 아래와 같이 세 텍스트 P, Q, R을 구성하는 단어의 집합이 다음과 같을 때, 자카드 유사도를 이용하여 가장 유사한 텍스트 두 개를 고르시오.

P={빨강, 노랑, 파랑}, Q={빨강, 초록, 보라}, R={초록, 파랑, 보라}

$$J(P,Q) = \frac{n(P \cap Q)}{n(P \cup Q)} = \frac{1}{5}, \qquad J(Q,R) = \frac{n(Q \cap R)}{n(Q \cup R)} = \frac{1}{2}, \qquad J(P,R) = \frac{n(P \cap R)}{n(P \cup R)} = \frac{1}{5}$$

- 따라서, Q와 R이 가장 유사하다.

자카드(Jaccard) 유사도 활용 예제 (2)

- 아래 영화 관람평으로부터 긍정 단어들에 대한 BOW와 부정 단어들에 대한 BOW를 구성하면 다음과 같다.

〈표 3.1〉 영화 관람평과 감정

영화 관람평	감정
재미있고 스토리와 연출도 최고! 꼭 보세요.	긍정
배우들의 연기가 감동이다. 스토리는 빈약합니다.	중립
정말 돈이 아깝고 가장 최악의 영화다.	부정
내 돈 돌려줘!	부정
배우들의 연기에 빠져들었다. 한번 더 봐도 좋다.	긍정
그럭저럭 시간 보내기에는 괜찮다. 연기는 별로!	중립

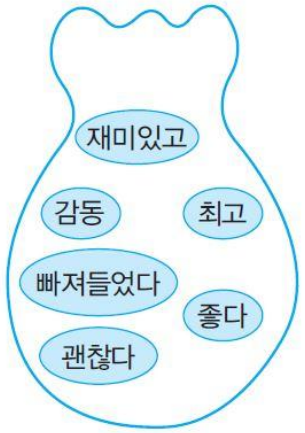

P : 긍정 단어를 포함하는 BOW

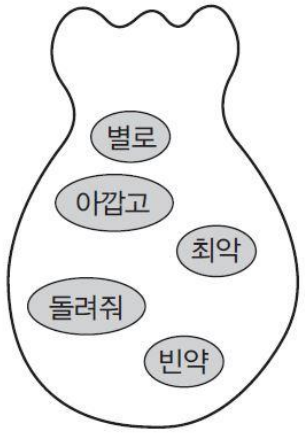

N : 부정 단어를 포함하는 BOW

P = {재미, 감동, 최고, 빠져들다, 좋다, 괜찮다}

N = {별로, 아깝다, 최악, 돌려주다, 빈약}

자카드(Jaccard) 유사도 활용 예제 (2)

- 이때, 새로 입력된 관람평 C는 긍정적/부정적 관람평 중 어디에 속하는가?

> **[관람평 C]** 내가 선호하지 않는 장르라서 큰 기대를 하지 않았는데, 스토리가 빈약하지 않고 괜찮다. 배우들의 연기도 최고라서 영화 보는 동안 감동에 빠져들었다.

P : 긍정 단어를 포함하는 BOW

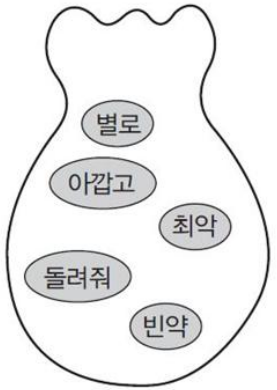

N : 부정 단어를 포함하는 BOW

- 새로운 관람평 C를 집합으로 표현하면 다음과 같다.

  C = {선호, 않다, 기대, 빈약, 괜찮다, 최고, 감동, 빠져들다}

- 새로운 관람평 C는 아래의 두 BOW 집합 P와 N 중 어떤 것과 더 가까운 지 비교한다.
  - P = {재미, 감동, 최고, 빠져들다, 좋다, 괜찮다}
  - N = {별로, 아깝다, 최악, 돌려주다, 빈약}

자카드(Jaccard) 유사도 활용 예제 (2)

- 이를 위해 "**P와 C의 자카드 유사도**"와 "**N과 C의 자카드 유사도**"를 비교한다.

P = {재미, 감동, 최고, 빠져들다, 좋다, 괜찮다}
N = {별로, 아깝다, 최악, 돌려주다, 빈약}
C = {선호, 않다, 기대, 빈약, 괜찮다, 최고, 감동, 빠져들다}

$$J(P,C) = \frac{n(P \cap C)}{n(P \cup C)} = \frac{4}{10} = 0.4$$

$$J(N,C) = \frac{n(N \cap C)}{n(N \cup C)} = \frac{1}{12} \cong 0.08$$

- $J(P,C) > J(N,C)$ **이므로 C는 P와 더 유사하다.**
- **즉, 새로운 관람평은 긍정의 관람평으로 분류된다.**

자카드(Jaccard) 유사도

예제 3.1 어떤 인공지능 스피커에 두 질문에 대한 단어들이 집합 A와 B로 각각 저장되어 있다.

$$A=\{\text{장르, 내일, 날씨, 뉴스, 깨워줘, 전화}\}$$
$$B=\{\text{날씨, 스포츠, 알람, 시계, 뉴스}\}$$

만일 인공지능 스피커에 새롭게 입력된 질문 C에 대한 단어 집합 C가 다음과 같을 때, 질문 C가 질문 A와 B 중에서 어떤 질문과 더 유사한지 판별하라.

$$C=\{\text{날씨, 알람, 체조, 뉴스}\}$$

자카드(Jaccard) 유사도

풀이

자카드 유사도 차 ΔJ를 구하기 위하여 $J(A,C)$와 $J(B,C)$를 각각 구하면 다음과 같다.

$$J(A,C)=\frac{n(A\cap C)}{n(A\cup C)}=\frac{2}{8}=0.25$$

$$J(B,C)=\frac{n(B\cap C)}{n(B\cup C)}=\frac{3}{6}=0.5$$

$$\therefore\ \Delta J=J(A,C)-J(B,C)=0.25-0.5=-0.25$$

따라서 질문 C는 질문 B와 더 유사하다고 판정한다.

Ⅲ. 두 벡터 사이의 거리

유클리드 거리 (Euclidean distance)

- 두 벡터 **a**와 **b**가 다음과 같이 주어졌을 때,

$$\boldsymbol{a} = [a_1, \dots, a_n]^T \in \mathbb{R}^n, \qquad \boldsymbol{b} = [b_1, \dots b_n]^T \in \mathbb{R}^n$$

- 벡터 **a**와 **b** 사이의 유클리드 거리는 다음과 같이 계산된다.

$$D_E(\boldsymbol{a}, \boldsymbol{b}) = \sqrt{(a_1 - b_1)^2 + \cdots + (a_n - b_n)^2}$$

$$= \sqrt{\sum_{i=1}^{n} (a_i - b_i)^2}$$

- 유클리드 거리의 용도
  - n차원의 벡터 공간 상에 정의되는 임의의 두 벡터 간의 거리 계산이 필요한 다양한 분야에서 가장 널리 활용됨

유클리드 거리 (Euclidean distance)

- 유클리드 거리 공식의 유도
  - 피타고라스의 정리를 응용하여 유도할 수 있다.
  - 증명을 간단히 하기 위해 2차원 평면 상에 두 점 $P(x_1, y_1)$, $Q(x_2, y_2)$를 잡는다.
  - 또한 P와 Q를 두 꼭지점으로 갖는 직각 삼각형의 나머지 점 $A(x_2, y_1)$를 잡는다.
  - 그렇다면, $\|\overline{PA}\| = x_2 - x_1$, $\|\overline{QA}\| = y_2 - y_1$이다.
  - 한편, 피타고라스 정리에 의해 $\|\overline{PQ}\| = \sqrt{\|\overline{PA}\|^2 + \|\overline{QA}\|^2}$ 이므로,

    $\|\overline{PQ}\| = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$이다.

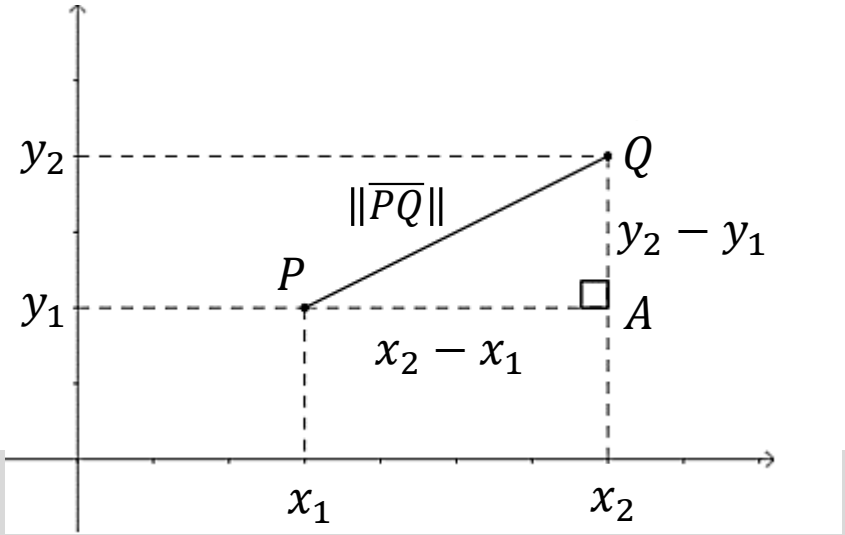

유클리드 거리의 활용

- 유클리드 거리는 두 벡터의 거리(유사도)를 측정하는 데 널리 활용된다.
- 이때, 두 벡터 간의 **거리가 가까울 수록** 유사도가 **높으며**,

  두 벡터 간의 **거리가 멀수록** 유사도가 **낮다**.
- 따라서, 거리와 유사도의 개념은 반대되는 개념임에 유의해야 한다.

유클리드 거리의 활용

예제 3.2

어떤 포털 사이트에 입력된 검색어 X와 연관 검색어로 고려되는 두 텍스트 데이터 A, B에 포함된 단어들의 빈도수 벡터가 각각 다음과 같다.

$$\boldsymbol{x}=(0, 1, 2, 1),\ \ \boldsymbol{a}=(1, 1, 2, 0),\ \ \boldsymbol{b}=(1, 0, 3, 0)$$

이때 두 텍스트 데이터 A와 B 중에서 검색어 X와 더 유사한 텍스트 데이터를 유클리디안 유사도를 이용하여 판별하라.

유클리드 거리의 활용

풀이

먼저 빈도수 벡터 $\boldsymbol{a}$와 $\boldsymbol{b}$에 대한 빈도수 벡터 $\boldsymbol{x}$의 유클리디안 유사도 $d(\boldsymbol{a}, \boldsymbol{x})$와 $d(\boldsymbol{b}, \boldsymbol{x})$를 각각 구하면 다음과 같다.

$$d(\boldsymbol{a}, \boldsymbol{x}) = \|\boldsymbol{x} - \boldsymbol{a}\| = \sqrt{(0-1)^2 + (1-1)^2 + (2-2)^2 + (1-0)^2} = \sqrt{2}$$
$$d(\boldsymbol{b}, \boldsymbol{x}) = \|\boldsymbol{x} - \boldsymbol{b}\| = \sqrt{(0-1)^2 + (1-0)^2 + (2-3)^2 + (1-0)^2} = 2$$

따라서 $d(\boldsymbol{a}, \boldsymbol{x}) < d(\boldsymbol{b}, \boldsymbol{x})$이므로 검색어 X는 텍스트 데이터 A와 더 가깝다.

맨하탄 거리 (Manhattan distance)

- 두 벡터 **a**와 **b**가 다음과 같이 주어질 때,

$$\boldsymbol{a} = [a_1, \dots, a_n]^T \in \mathbb{R}^n, \qquad \boldsymbol{b} = [b_1, \dots b_n]^T \in \mathbb{R}^n$$

- 벡터 **a**와 **b** 사이의 **맨하탄 거리**는 다음과 같이 계산된다.

$$D_M(\boldsymbol{a}, \boldsymbol{b}) = |a_1 - b_1| + \cdots |a_n - b_n|$$

$$= \sum_{i=1}^{n} |a_i - b_i|$$

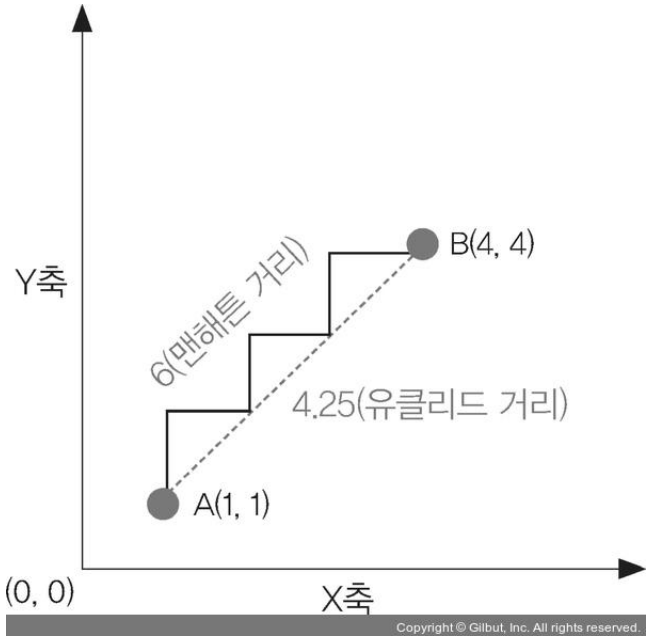

- 맨하탄 거리의 용도
  - ➢ 2차원 평면 상에서 두 지점 간의 거리 계산 시 장애물을 고려해야 하는 경우
  - ➢ 이동 시 대각선을 고려할 수 없을 때, 최단 거리를 계산해야 하는 경우

맨하탄 거리 (Manhattan distance)

- 맨하탄 거리와 유클리드 거리의 비교

맨하탄 거리	유클리드 거리
$D_M(\boldsymbol{a},\boldsymbol{b}) = \sum_{i=1}^{n} \lvert a_i - b_i \rvert$	$D_E(\boldsymbol{a},\boldsymbol{b}) = \sqrt{\sum_{i=1}^{n} (a_i - b_i)^2}$

➢ **맨하탄 거리** : A에서 B(또는 B에서 A)로 갈 때, 가로지르지 않고 갈 수 있는 최단 거리

➢ **유클리드 거리** : A에서 B(또는 B에서 A)로 갈 때의 최단 거리로 가로지르는 것도 허용

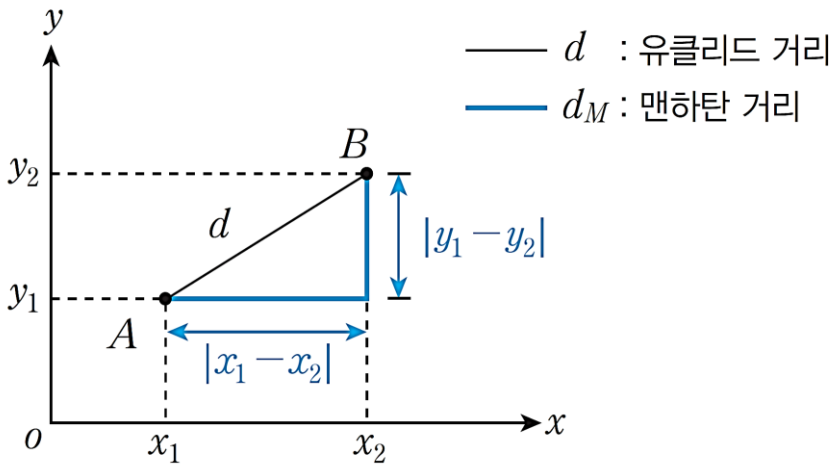

[그림 3.10] 맨하탄 거리의 정의

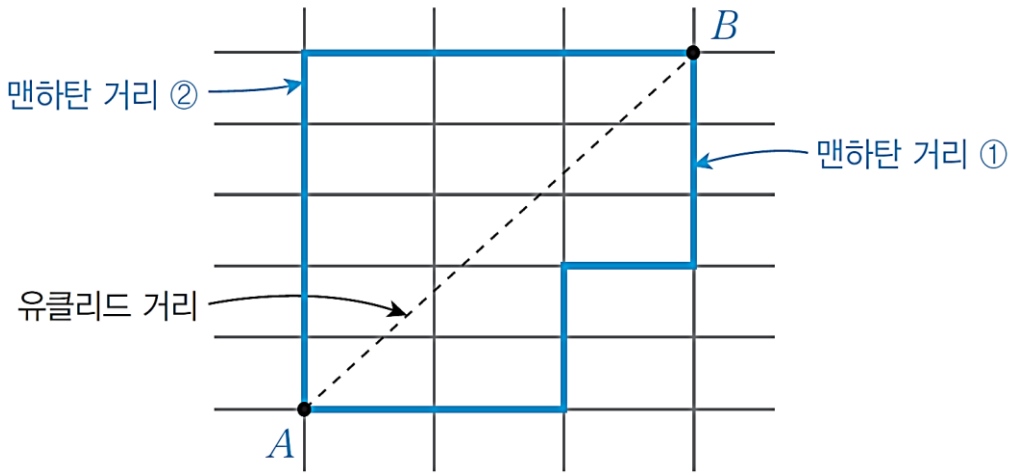

[그림 3.11] 맨하탄 거리의 개념

맨하탄 거리 (Manhattan distance)

예제 3.7

3차원 벡터 $\boldsymbol{a}=(1, 0, m)$, $\boldsymbol{b}=(2, 1, 3)$일 때, $d_M(\boldsymbol{a}, \boldsymbol{b})=4$가 되도록 상수 m의 값을 구하라.

풀이

두 벡터 $\boldsymbol{a}$, $\boldsymbol{b}$의 맨하탄 거리는 식(21)로부터 다음과 같이 구해진다.

$$d_M(\boldsymbol{a}, \boldsymbol{b})=|1-2|+|0-1|+|m-3|=2+|m-3|=4$$

$$|m-3|=2 \longrightarrow m-3=\pm 2$$

$$\therefore\ m=5 \quad \text{또는} \quad m=1$$

민코스키 거리 (Minkowski distance)

- 두 벡터 **a**와 **b**가 다음과 같이 주어졌을 때,

$$\boldsymbol{a} = [a_1, \dots, a_n]^T \in \mathbb{R}^n, \qquad \boldsymbol{b} = [b_1, \dots b_n]^T \in \mathbb{R}^n$$

- 벡터 **a**와 **b** 사이의 민코스키 거리는 다음과 같이 계산된다.

$$D_{MN}(\boldsymbol{a}, \boldsymbol{b}) = |a_1 - b_1|^p + \cdots |a_n - b_n|^p = \left(\sum_{i=1}^{n} |a_i - b_i|^p \right)^{\frac{1}{p}}$$

- 민코스키 거리는 맨하탄 거리와 유클리드 거리의 **일반화**된 형태
  - **p = 1인 경우 : 맨하탄 거리**
  - **p = 2인 경우 : 유클리드 거리**
  - p = ∞인 경우 : Chebyshev 거리

Chebyshev 거리

- 두 벡터 **a**와 **b**가 다음과 같이 주어졌을 때,

$$\boldsymbol{a} = [a_1, \dots, a_n]^T \in \mathbb{R}^n, \qquad \boldsymbol{b} = [b_1, \dots b_n]^T \in \mathbb{R}^n$$

- 벡터 **a**와 **b** 사이의 Chebyshev distance는 다음과 같이 계산된다.

$$D_C(\boldsymbol{a}, \boldsymbol{b}) = \lim_{p \to \infty} \left(\sum_{i=1}^{n} |a_i - b_i|^p \right)^{\frac{1}{p}} = \max_i (|a_i - b_i|)$$

두 벡터 간의 거리를 계산하는 방법들의 비교

- 앞서 배운 세 가지 유사도 계산 방법을 이용하여 아래 체스 보드의 가운데 지점에서 각 지점까지의 거리를 계산하면 다음과 같다.

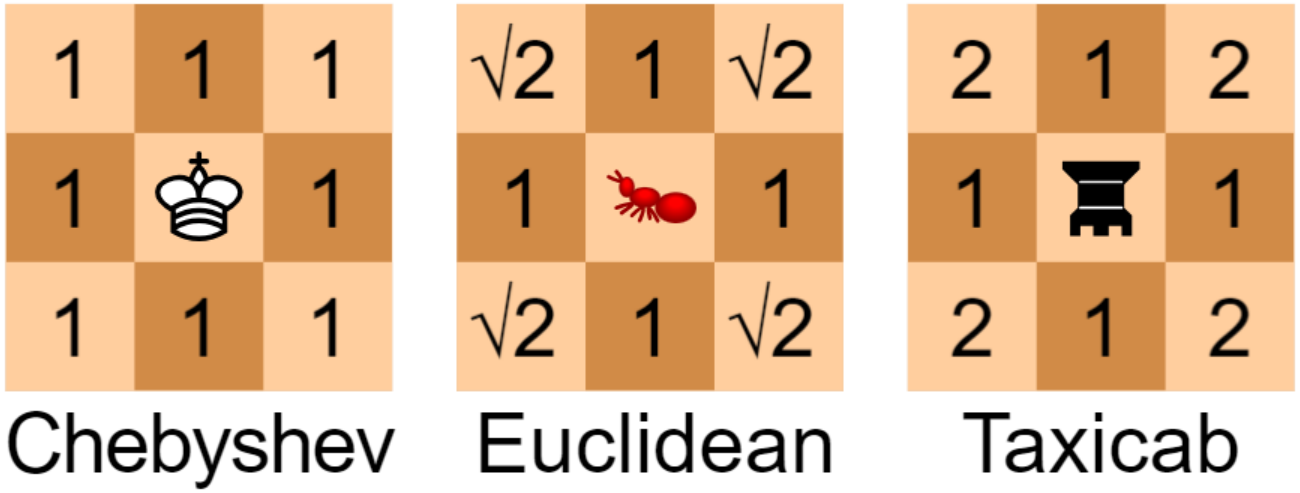

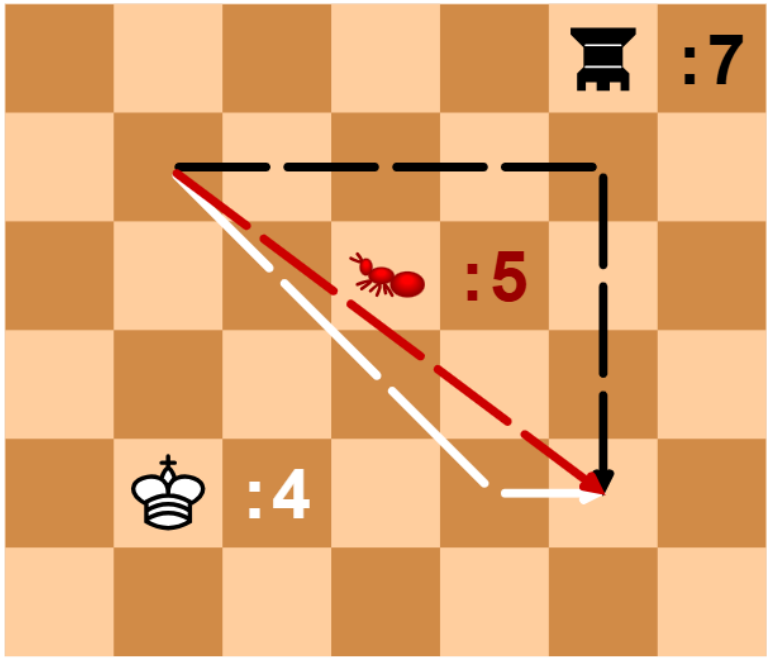

Reference: https://en.wikipedia.org/wiki/Chebyshev_distance

[실습] 벡터 거리 함수의 구현

- ① 두 벡터 **a**와 **b** 사이의 거리를 계산하는 유클리드 거리 계산 함수 **EuclidDist(a, b)**와 맨하탄 거리 계산 함수 **ManhattanDist(a, b)**를 구현하시오.
  - ➢ 단, 구현 시 라이브러리는 사용하지 말 것.
- ② 아래의 예제 벡터들이 주어졌을 때, 위에서 구현한 유클리드 거리와 맨하탄 거리 함수를 이용하여 각 벡터 간의 거리를 계산하고, 가장 유사한 두 벡터의 쌍(pair)은 무엇인지 확인하시오.

$$\overrightarrow{D_1} = [0.32, 0.57, 0.65, 0.53, 0.57, 0.15, 0.81, 0.75]$$
$$\overrightarrow{D_2} = [0.54, 0.12, 0.98, 0.13, 0.51, 0.14, 0.88, 0.12]$$
$$\overrightarrow{D_3} = [0.05, 0.47, 0.31, 0.49, 0.19, 0.24, 0.04, 0.34]$$
$$\overrightarrow{D_4} = [0.38, 0.58, 0.61, 0.58, 0.49, 0.25, 0.83, 0.77]$$
$$\overrightarrow{D_5} = [0.51, 0.27, 0.75, 0.33, 0.38, 0.48, 0.55, 0.64]$$
$$\overrightarrow{D_6} = [0.28, 0.32, 0.45, 0.75, 0.35, 0.98, 0.38, 0.88]$$

[실습] 벡터 거리 함수의 구현

- ③ 새로운 입력 벡터

$$\overrightarrow{D_N} = [0.48, 0.61, 0.37, 0.64, 0.21, 0.21, 0.17, 0.75]$$

이 주어졌을 때, 어떤 문서와 가장 유사한 지 분류하시오.

$$\overrightarrow{D_1} = [0.32, 0.57, 0.65, 0.53, 0.57, 0.15, 0.81, 0.75]$$
$$\overrightarrow{D_2} = [0.54, 0.12, 0.98, 0.13, 0.51, 0.14, 0.88, 0.12]$$
$$\overrightarrow{D_3} = [0.05, 0.47, 0.31, 0.49, 0.19, 0.24, 0.04, 0.34]$$
$$\overrightarrow{D_4} = [0.38, 0.58, 0.61, 0.58, 0.49, 0.25, 0.83, 0.77]$$
$$\overrightarrow{D_5} = [0.51, 0.27, 0.75, 0.33, 0.38, 0.48, 0.55, 0.64]$$
$$\overrightarrow{D_6} = [0.28, 0.32, 0.45, 0.75, 0.35, 0.98, 0.38, 0.88]$$

Ⅲ. 코사인 유사도

벡터의 내적

- 벡터의 내적(Inner Product)은 두 벡터의 방향의 일치 정도를 확인할 때 자주 사용되는 연산으로, 스칼라적(Scalar Product)이라고도 부른다.
- 두 벡터 **a**와 **b**의 내적은 다음과 같이 정의된다.

$$\boldsymbol{a} \cdot \boldsymbol{b} \triangleq \|\boldsymbol{a}\|\|\boldsymbol{b}\| \cos\theta$$

θ : 벡터 **a**와 **b** 사이의 각$(0 \le \theta \le \pi)$

- 벡터의 내적과 수직(perpendicular)
  - 두 벡터 **a**와 **b**가 서로 직교(수직)하면 두 벡터의 내적은 0이다. (즉, $\boldsymbol{a}\cdot\boldsymbol{b}=0$)
  - 이는, 두 벡터가 서로 상관관계가 없이 독립적이라는 의미이다.
  - 즉, 벡터 **a**는 벡터 **b**의 선형 조합으로 표현될 수 없다는 의미이다(and vice versa).

벡터의 내적

- 내적의 기하학적 의미
  - ➢ 벡터 $\boldsymbol{a}$를 벡터 $\boldsymbol{b}$에 투영(Projection)시킨 벡터의 크기는 $\|\boldsymbol{a}\|\cos\theta$이다.
  - ➢ 따라서, 내적 $\boldsymbol{a}\cdot\boldsymbol{b}$는 $\boldsymbol{a}$를 $\boldsymbol{b}$에 투영시킨 크기와 $\boldsymbol{b}$의 크기(= $\|\boldsymbol{b}\|$)의 곱이다.

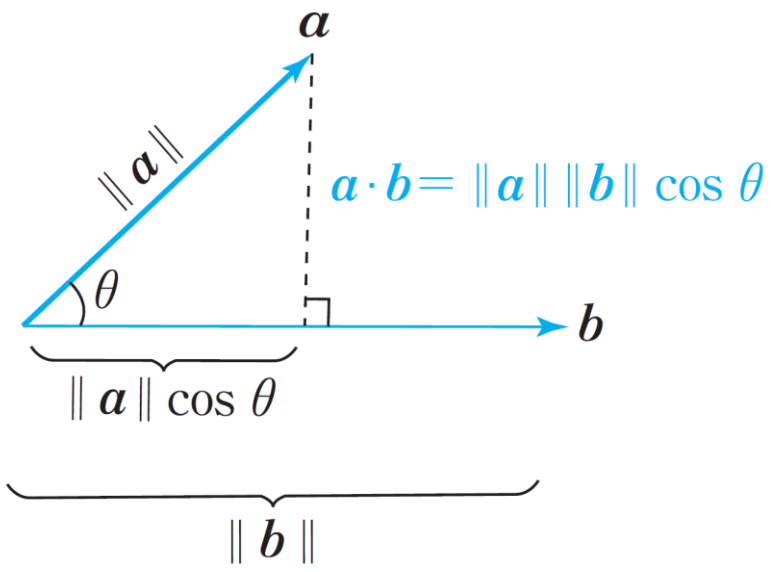

[그림 3.6] 내적 $\boldsymbol{a}\cdot\boldsymbol{b}$의 기하학적 의미

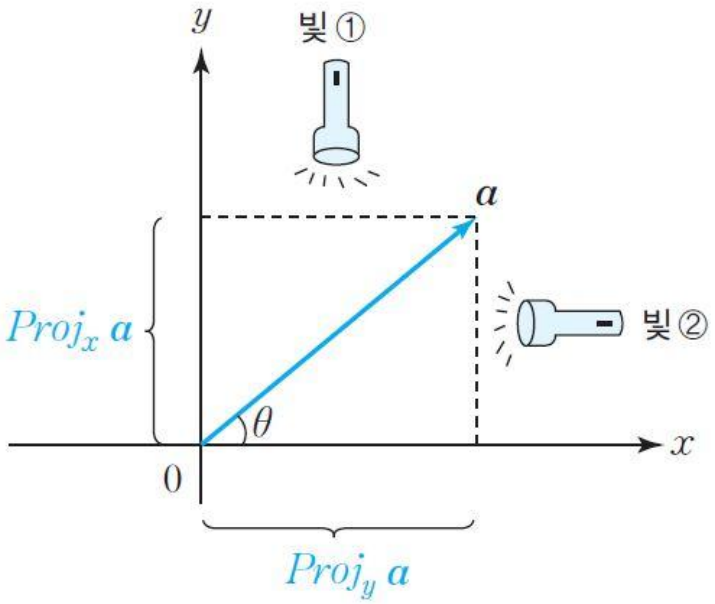

[그림 3.7] 투영의 개념

벡터의 내적 공식 유도

- 벡터의 내적을 계산하는 방법
  - ➢ 벡터의 내적을 계산하는 공식은 제2 코사인법칙을 이용하여 유도할 수 있다.
  - ➢ 제1 코사인법칙
    - $a = b\cos C + c\cos B$
    - $b = c\cos A + a\cos C$
    - $c = a\cos B + b\cos A$
  - ➢ 제2 코사인법칙
    - $a^2 = b^2 + c^2 - 2bc\cos A$
    - $b^2 = a^2 + c^2 - 2ac\cos B$
    - $c^2 = a^2 + b^2 - 2ab\cos C$

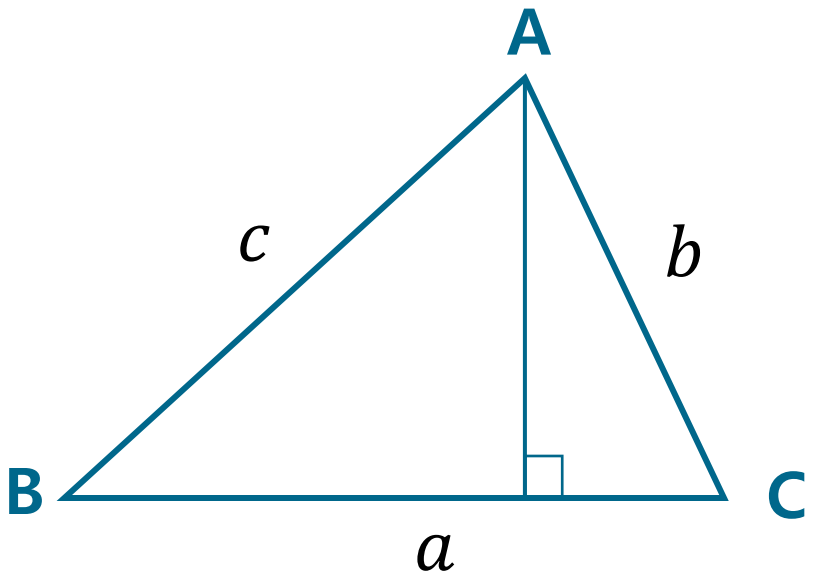

벡터의 내적 공식 유도

- 제2 코사인법칙으로부터 벡터의 내적 계산 공식 유도
  - 제2 코사인법칙 $c^2 = a^2 + b^2 - 2ab\cos C$을 왼쪽의 삼각형에 대하여 적용해보자.
  - 즉, $\|c\|^2 = \|a\|^2 + \|b\|^2 - 2\|a\|\|b\|\cos\theta$이고, 이에 따라

$$\|a\|\|b\|\cos\theta = \frac{1}{2}(\|a\|^2 + \|b\|^2 - \|c\|^2)$$

이다.

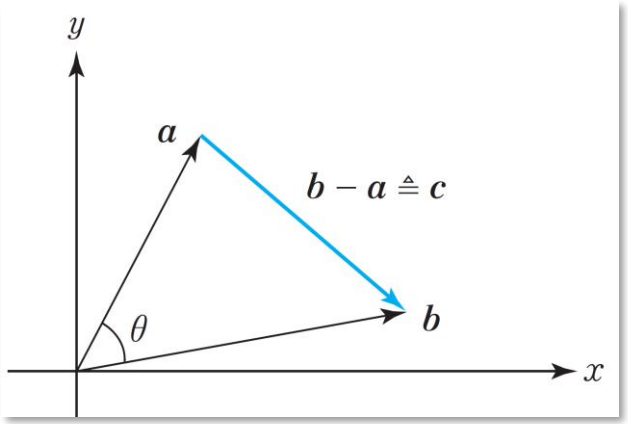

  - 위 등식에서 좌변은 내적의 정리에 따라 $\boldsymbol{a}\cdot\boldsymbol{b}$이다.
  - 한편, 우변의 $\|a\|^2$, $\|b\|^2$, $\|c\|^2$은 각각 $\|a\|^2 = \sum_{i=1}^{n} a_i^2$, $\|b\|^2 = \sum_{i=1}^{n} b_i^2$ 이고,

    $\|c\|^2 = \sum_{i=1}^{n} c_i^2 = \sum_{i=1}^{n}(b_i - a_i)^2$ 이다.
  - 이를 정리하면, $\boldsymbol{a}\cdot\boldsymbol{b} = \frac{1}{2}\left(\sum_{i=1}^{n} a_i^2 + \sum_{i=1}^{n} b_i^2 - \sum_{i=1}^{n}(b_i - a_i)^2\right) = \sum_{i=1}^{n} a_i b_i$ 이다.
  - 따라서, $\boldsymbol{a}\cdot\boldsymbol{b} = \sum_{i=1}^{n} a_i b_i$ 이다.

두 벡터의 유사도를 측정하는 방법

- 벡터 공간에서 두 벡터가 이루는 사이각의 크기(= θ)를 이용하여 두 벡터의 유사도를 계산할 수 있다.
  - ➢ 두 벡터의 사이각이 0에 가까울수록 ➔ 두 벡터는 서로 유사함
  - ➢ 두 벡터의 사이각이 90도에 가까울수록 ➔ 두 벡터는 서로 독립적임
  - ➢ 두 벡터의 사이각이 180도에 가까울수록 ➔ 두 벡터는 서로 상반되는 관계
- 이를 두 벡터의 성분을 이용하여 계산하는 대표적인 방법으로 코사인 유사도 (Cosine similarity)가 널리 활용된다.

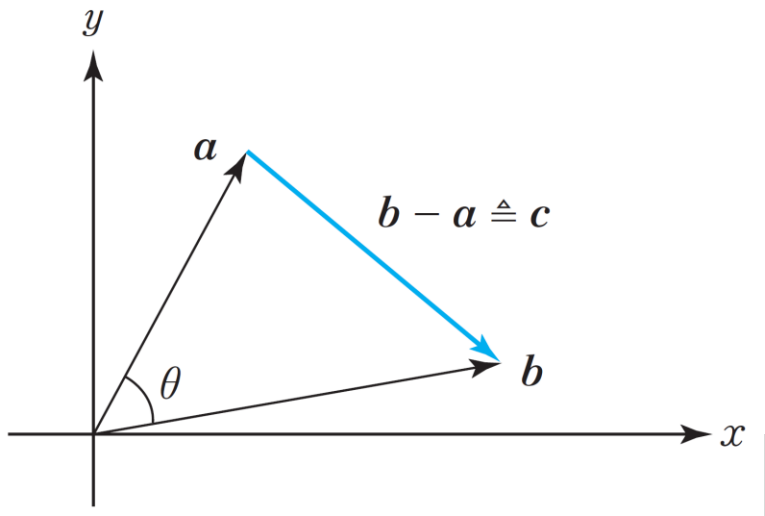

코사인 유사도 (Cosine similarity)

- 두 벡터 **a**와 **b**가 다음과 같이 주어졌을 때,

$$\boldsymbol{a} = [a_1, \dots, a_n]^T \in \mathbb{R}^n, \qquad \boldsymbol{b} = [b_1, \dots b_n]^T \in \mathbb{R}^n$$

- 벡터 **a**와 **b**의 코사인 유사도는 다음과 같이 계산된다.

$$sim_c(\boldsymbol{a}, \boldsymbol{b}) \triangleq \frac{\boldsymbol{a} \cdot \boldsymbol{b}}{\|\boldsymbol{a}\|\|\boldsymbol{b}\|} = \frac{\boldsymbol{a}}{\|\boldsymbol{a}\|} \cdot \frac{\boldsymbol{b}}{\|\boldsymbol{b}\|}$$

- 코사인 유사도 공식의 분석
  - ➢ 벡터 **a**와 벡터 **b**를 각각 자신의 크기로 나누어 정규화한 후, 이들의 내적을 계산한 결과와 동일하다.
  - ➢ 결과적으로 코사인 유사도는 벡터 **a**와 **b**의 내적으로부터 직접적으로 유도된다.

코사인 유사도 (Cosine similarity)

- 코사인 유사도는 두 벡터 간의 코사인 각도를 이용하여 구할 수 있는 두 벡터의 유사도를 의미함.
- 두 벡터의 방향이 완전히 동일한 경우에는 1, 90°의 각을 이루면 0, 180°로 반대의 방향을 가지면 -1.
- 즉, 코사인 유사도 결과값이 1에 가까울수록 유사도가 높으며, 1에서 멀어질수록 두 벡터의 유사도는 낮은 것으로 볼 수 있음.

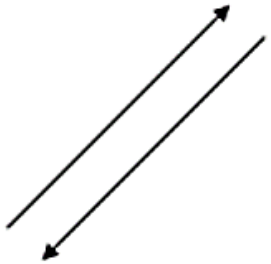

코사인 유사도 : -1

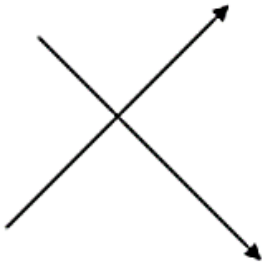

코사인 유사도 : 0

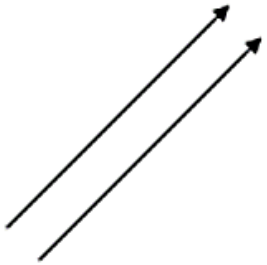

코사인 유사도 : 1

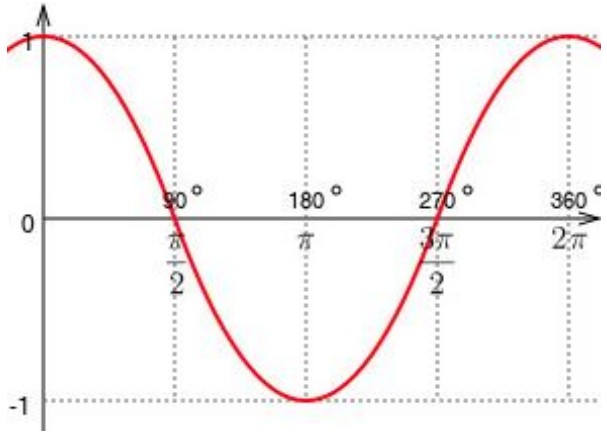

코사인 유사도 (Cosine similarity)

예제 3.3

$\boldsymbol{a}=(2,1,0)$, $\boldsymbol{b}=(1,1,1)$에 대하여 다음 물음에 답하라.

(1) $\boldsymbol{a}$와 $\boldsymbol{b}$가 이루는 사이 각 θ에 대한 코사인 유사도를 계산하시오.

(2) 다음과 같이 정의된 $\boldsymbol{c}$는 $\boldsymbol{a}$와 수직임을 증명하라.

$$\boldsymbol{c}=\boldsymbol{b}-\frac{\boldsymbol{a}\cdot\boldsymbol{b}}{\|\boldsymbol{a}\|^2}\boldsymbol{a}$$

코사인 유사도 (Cosine similarity)

풀이

(1) $\boldsymbol{a}\cdot\boldsymbol{b}=2+1+0=3$

$$\|\boldsymbol{a}\|=\sqrt{5},\ \|\boldsymbol{b}\|=\sqrt{3}$$

$$\therefore\ \cos\theta=\frac{\boldsymbol{a}\cdot\boldsymbol{b}}{\|a\|\,\|b\|}=\frac{3}{\sqrt{5}\cdot\sqrt{3}}=\frac{3}{\sqrt{15}}$$

(2) $\boldsymbol{c}$와 $\boldsymbol{a}$의 내적을 계산해 보면

$$\begin{aligned}\boldsymbol{c}\cdot\boldsymbol{a}&=\left(\boldsymbol{b}-\frac{\boldsymbol{a}\cdot\boldsymbol{b}}{\|\boldsymbol{a}\|^2}\boldsymbol{a}\right)\cdot\boldsymbol{a}\\&=\boldsymbol{a}\cdot\boldsymbol{b}-\frac{\boldsymbol{a}\cdot\boldsymbol{b}}{\|\boldsymbol{a}\|^2}(\boldsymbol{a}\cdot\boldsymbol{a})\\&=\boldsymbol{a}\cdot\boldsymbol{b}-\frac{\boldsymbol{a}\cdot\boldsymbol{b}}{\|\boldsymbol{a}\|^2}\|\boldsymbol{a}\|^2=\boldsymbol{a}\cdot\boldsymbol{b}-\boldsymbol{a}\cdot\boldsymbol{b}=0\end{aligned}$$

이므로 $\boldsymbol{c}$와 $\boldsymbol{a}$는 서로 수직이다.

코사인 유사도 (Cosine similarity)

예제 3.4

세 벡터 $\boldsymbol{a}$, $\boldsymbol{b}$, $\boldsymbol{c}$가 각각 다음과 같다고 할 때, 코사인 유사도 $C(\boldsymbol{a}, \boldsymbol{b})$와 $C(\boldsymbol{a}, \boldsymbol{c})$를 각각 구하라.

$$\boldsymbol{a}=(1, 0, 3),\ \ \boldsymbol{b}=(2, 1, 1),\ \ \boldsymbol{c}=(1, 1, 2)$$

풀이

$$C(\boldsymbol{a}, \boldsymbol{b})=\frac{\boldsymbol{a}\cdot\boldsymbol{b}}{\|\boldsymbol{a}\|\,\|\boldsymbol{b}\|}=\frac{2+0+3}{\sqrt{10}\sqrt{6}}=\frac{5}{\sqrt{60}}$$

$$C(\boldsymbol{a}, \boldsymbol{c})=\frac{\boldsymbol{a}\cdot\boldsymbol{c}}{\|\boldsymbol{a}\|\,\|\boldsymbol{c}\|}=\frac{1+0+6}{\sqrt{10}\sqrt{6}}=\frac{7}{\sqrt{60}}$$

$C(\boldsymbol{a}, \boldsymbol{b}) < C(\boldsymbol{a}, \boldsymbol{c})$이므로 벡터 $\boldsymbol{a}$는 벡터 $\boldsymbol{c}$와 더 유사하다고 할 수 있다.

유클리드 거리와 코사인 유사도의 비교

- 두 유사도는 유사성을 판별하는 기준이 다르기 때문에 인공지능의 결과가 다르게 나타날 수도 있다.
  - ➢ 유클리드 거리: 두 벡터 사이의 거리가 가까울수록 유사도가 높다고 판단한다.
  - ➢ 코사인 유사도: 두 벡터의 방향이 가까울수록, 즉, 사이각이 작을수록 유사도가 높다고 판단한다.
- 유클리드 거리의 결과값은 두 벡터 사이의 거리이므로 최대 값의 제한 범위가 없으므로 추가적인 판별기준이 필요하다.
- 한편, 코사인 유사도의 경우 두 벡터 사이의 각이므로 유사성을 판별하기에 보다 직관적인 장점이 있다.

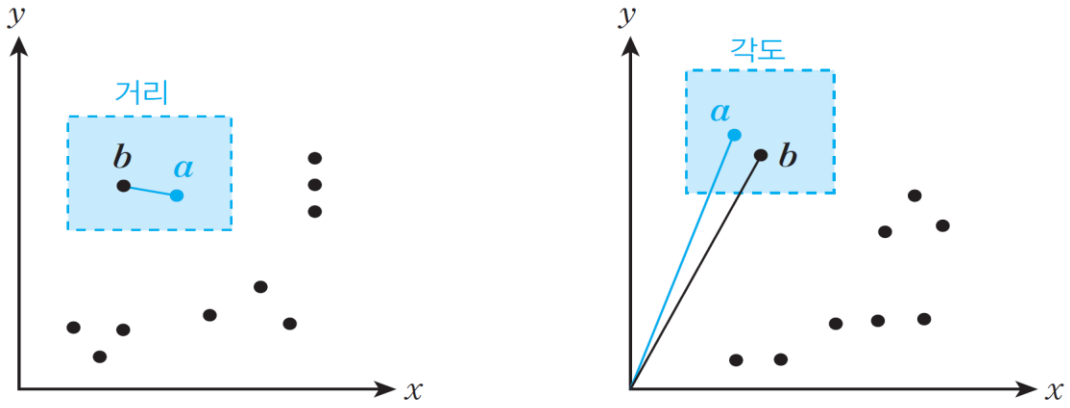

(a) 유클라디안 유사도(거리 기반) (b) 코사인 유사도(각도 기반)

유클리드 거리와 코사인 유사도의 비교

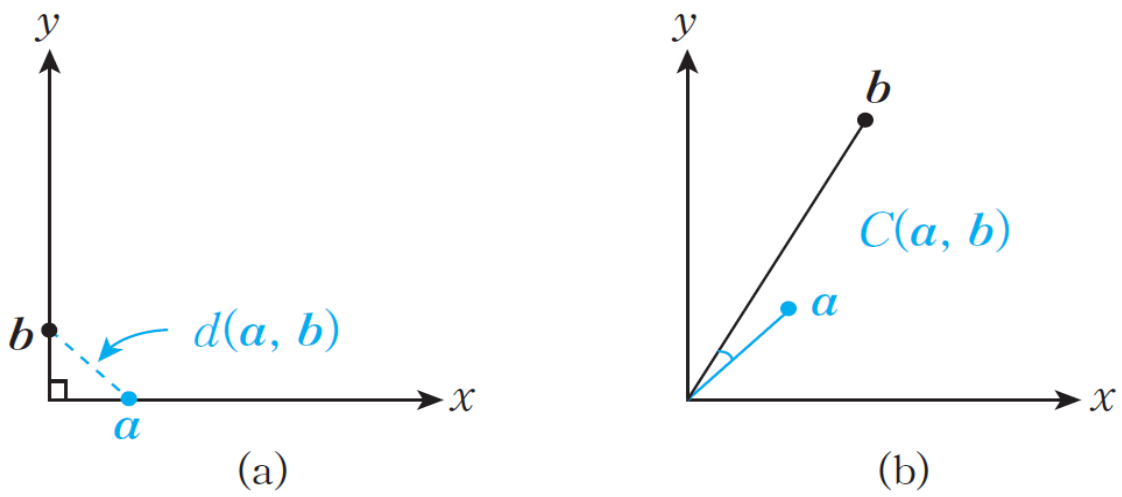

- 그림 (a)에서 두 벡터 **a**와 **b**의 거리는 가깝지만 사이각이 90도이므로, 코사인 유사도로 계산할 경우, 유사하지 않다고 판정하고, 반면에 유클리드 거리로 계산할 경우 거리가 가까운 것으로 판정함
- 그림 (b)에서 두 벡터 **a**와 **b**의 거리는 멀지만 사이각은 작으므로, 코사인 유사도를 사용하면 유사도가 큰 것으로, 유클리드 거리로 계산할 경우 두 벡터의 유사도를 낮은 것으로 판단함
- 이는 두 방법의 유사도를 판단하는 기준이 다르기 때문에 발생하는 현상임

IV. 상관 계수

상관 계수(Correlation coefficient)

- 두 변수 간의 상호 종속관계를 측정해 주는 계수로서 -1에서 1까지의 값을 가짐
- 즉, 상관관계 분석에서 두 변수 간에 선형 관계의 정도를 수량화하는 측도
  - ➢ 상관관계 분석(Correlation Analysis)은 두 변수 간의 관계를 측정하고 그 강도와 방향을 확인하는 통계적 방법
- **피어슨 상관 계수(Pearson correlation coefficient)**
  - ➢ 두 변량 x와 y의 공분산을 $cov(x, y)$, x와 y의 표준편차를 각각 $std(x)$, $std(y)$라 할 때, 피어슨 상관 계수는 다음과 같이 계산된다.

$$PCC(x, y) = \frac{cov(x, y)}{std(x) \times std(y)}$$

[공분산]

$$cov(x, y) = \frac{\sum(x - \bar{x})(y - \bar{y})}{n}$$

[표준편차]

$$std(x) = \sqrt{\frac{\sum(x - \bar{x})^2}{n}}$$

피어슨 상관 계수 (Pearson Correlation Coefficient : PCC)

- 두 변량 간의 상관관계(correlation)를 파악하기 위한 대표적인 방법
- 두 벡터 **a**와 **b**에 대한 PCC는 다음과 같이 계산할 수 있다.

$$PCC(\boldsymbol{a},\boldsymbol{b}) = \frac{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})(b_i - \mu_{\boldsymbol{b}})}{\sqrt{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})^2}\sqrt{\sum_{i=1}^{n}(b_i - \mu_{\boldsymbol{b}})^2}}$$

- $\mu_{\boldsymbol{a}} = \frac{1}{n}\sum_{i=1}^{n} a_i$
- $\mu_{\boldsymbol{b}} = \frac{1}{n}\sum_{i=1}^{n} b_i$

  - 결과는 -1 ~ 1 사이의 범위를 갖는다.
  - -1에 가까울수록 두 벡터 **a**와 **b**는 서로 반대되는 상관관계를 갖는다.
  - 1에 가까울수록 두 벡터 **a**와 **b**는 서로 유사한 상관관계를 갖는다.
  - 0인 경우 **a**와 **b**는 서로 상관관계가 존재하지 않는다.

PCC 공식의 분석

- 두 벡터 **a**와 **b**의 PCC 공식의 의미를 분석하면 다음과 같다.

$$PCC(\boldsymbol{a},\boldsymbol{b}) = \frac{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})(b_i - \mu_{\boldsymbol{b}})}{\sqrt{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})^2}\sqrt{\sum_{i=1}^{n}(b_i - \mu_{\boldsymbol{b}})^2}}$$

- $\mu_{\boldsymbol{a}} = \frac{1}{n}\sum_{i=1}^{n} a_i$
- $\mu_{\boldsymbol{b}} = \frac{1}{n}\sum_{i=1}^{n} b_i$

✓ $a_i - \mu_{\boldsymbol{a}}$: 벡터 **a**를 평균이 0인 벡터로 변환

✓ $b_i - \mu_{\boldsymbol{b}}$: 벡터 **b**를 평균이 0인 벡터로 변환

✓ $\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})(b_i - \mu_{\boldsymbol{b}})$: 벡터 **a**와 **b**의 공분산(covariance)

✓ $\sqrt{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})^2}$: 벡터 **a**의 표준편차(standard deviation)

✓ $\sqrt{\sum_{i=1}^{n}(b_i - \mu_{\boldsymbol{b}})^2}$: 벡터 **b**의 표준편차(standard deviation)

[공분산]

$$cov(x,y) = \frac{\sum(x-\bar{x})(y-\bar{y})}{n}$$

[표준편차]

$$std(x,y) = \sqrt{\frac{\sum(x-\bar{x})^2}{n}}$$

PCC 공식의 분석

- 코사인 유사도와 PCC 공식의 비교

$$sim_c(\boldsymbol{a}, \boldsymbol{b}) = \frac{\boldsymbol{a} \cdot \boldsymbol{b}}{\|\boldsymbol{a}\|\|\boldsymbol{b}\|} = \frac{\sum_{i=1}^{n} a_i b_i}{\sqrt{\sum_{i=1}^{n} a_i} \ \sqrt{\sum_{i=1}^{n} b_i}}$$

$$PCC(\boldsymbol{a}, \boldsymbol{b}) = \frac{\sum_{i=1}^{n} (a_i - \mu_{\boldsymbol{a}})(b_i - \mu_{\boldsymbol{b}})}{\sqrt{\sum_{i=1}^{n} (a_i - \mu_{\boldsymbol{a}})^2} \sqrt{\sum_{i=1}^{n} (b_i - \mu_{\boldsymbol{b}})^2}}$$

- $\mu_{\boldsymbol{a}} = \frac{1}{n} \sum_{i=1}^{n} a_i$
- $\mu_{\boldsymbol{b}} = \frac{1}{n} \sum_{i=1}^{n} b_i$

➢ PCC와 코사인 유사도는 매우 유사한 구조를 가진다.

➢ 그렇다면, 두 공식에서 발견되는 차이점은 무엇인가?

PCC 공식의 분석

- 코사인 유사도와 PCC는 어떠한 관계가 있는가?

$$PCC(\boldsymbol{a},\boldsymbol{b}) = \frac{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})(b_i - \mu_{\boldsymbol{b}})}{\sqrt{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})^2}\sqrt{\sum_{i=1}^{n}(b_i - \mu_{\boldsymbol{b}})^2}}$$

- $\mu_{\boldsymbol{a}} = \frac{1}{n}\sum_{i=1}^{n} a_i$
- $\mu_{\boldsymbol{b}} = \frac{1}{n}\sum_{i=1}^{n} b_i$

➢ 두 벡터 **a**와 **b**의 PCC는 아래의 변환 과정을 통해 코사인 유사도로부터 직접적으로 유도된다.

- 위 공식은 벡터 내 성분들의 평균을 0으로, 표준편차를 1로 조정한 두 벡터에 대하여 코사인 유사도를 계산한 결과와 같다.
- 즉, PCC는 코사인 유사도와 동일하게 -1 ~ 1의 범위를 갖는다.

Pearson Correlation Coefficient (PCC)

- 두 변량 a와 b간의 PCC와 분포 형태

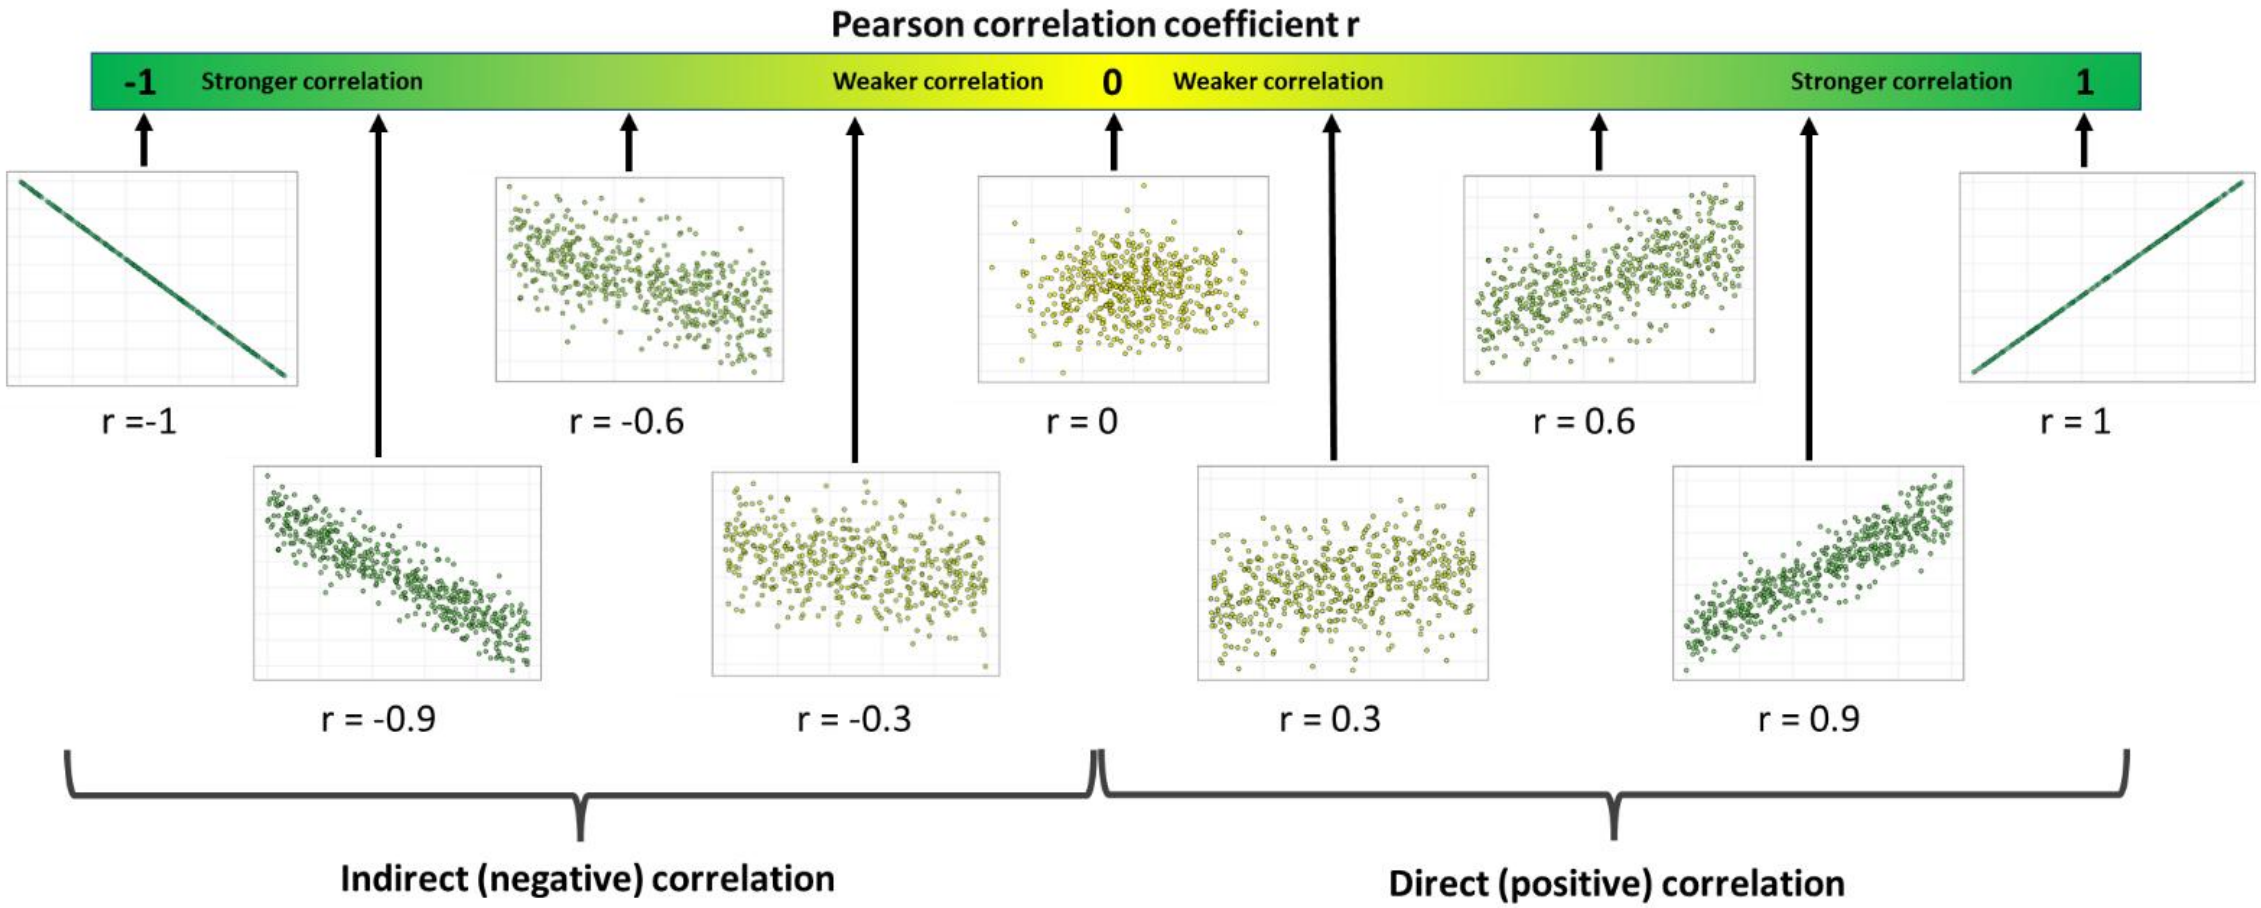

Pearson Correlation Coefficient (PCC)

- PCC 값의 범위(-1 ~ 1)에 따른 두 변량 $\boldsymbol{a}$와 $\boldsymbol{b}$간의 상관성의 정도

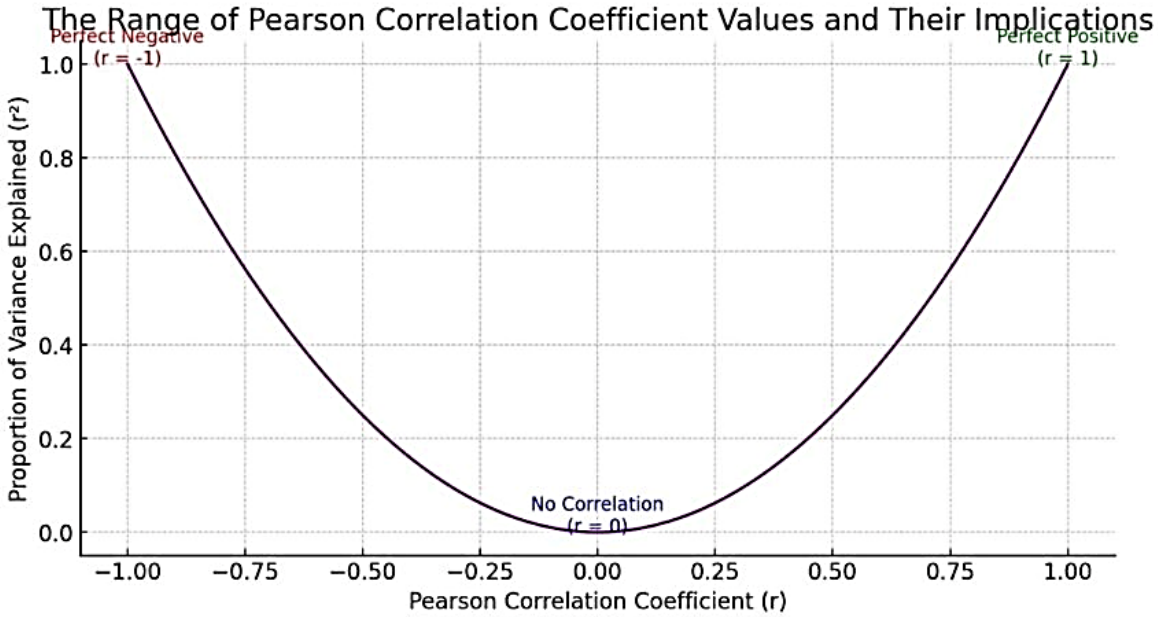

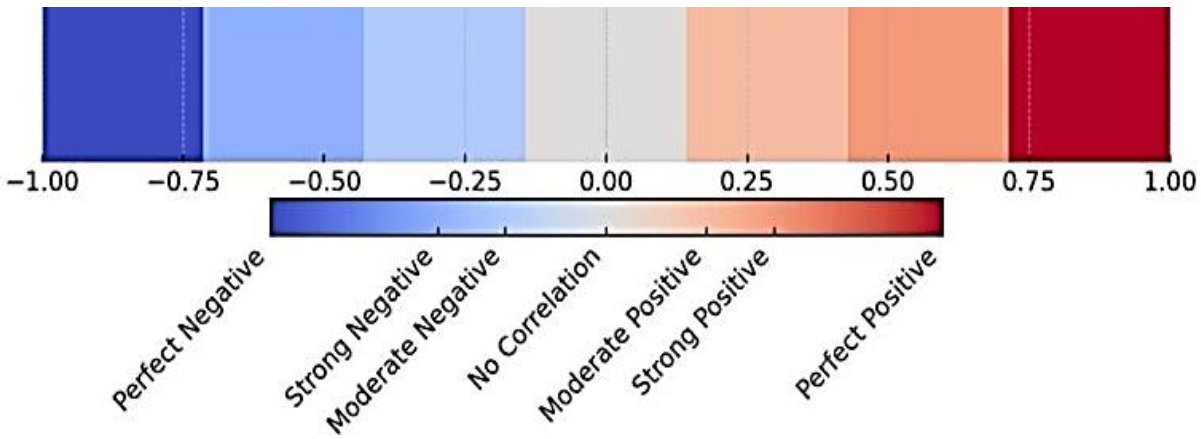

Reference: StatisticsEasily.com

PCC 공식의 다른 버전

$$PCC(\boldsymbol{a},\boldsymbol{b}) = \frac{n\sum_{i=1}^{n} a_i b_i - (\sum_{i=1}^{n} a_i)(\sum_{i=1}^{n} b_i)}{\sqrt{n\sum_{i=1}^{n} a_i^2 - \left(\sum_{i=1}^{n} a_i\right)^2}\ \sqrt{n\sum_{i=1}^{n} b_i^2 - \left(\sum_{i=1}^{n} b_i\right)^2}}$$

- ✓ 상기 버전은 앞서 설명한 PCC 공식과 형태는 다르지만 근본적으로 동일함
  (※ 앞서 설명한 PCC 공식을 전개한 후 식을 정리하면 위의 식을 얻을 수 있음)
- ✓ 앞의 PCC와는 달리 벡터 **a**와 **b**에 대한 합을 계산하는 항(term)이 구분되어 있음

➔ $\sum_{i=1}^{n} a_i$, $\sum_{i=1}^{n} b_i$, $\sum_{i=1}^{n} a_i b_i$, $\sum_{i=1}^{n} a_i^2$, $\sum_{i=1}^{n} b_i^2$, n

- ➢ 위 공식을 이용하면 두 벡터 **a**와 **b**의 성분이 지속적으로 변화하는 환경에서, 변경된 성분에 대해서만 업데이트함으로써 두 벡터의 유사도를 효율적으로 계산할 수 있는 incremental computation이 가능하다.
- ➢ 이를 실제 구현하기 위해서는 상기 6개 항(term)의 계산 결과를 별도의 공간에 캐싱(caching) 해야 함

PCC 공식 요약

- 두 벡터 **a**와 **b**에 대한 PCC 공식 비교

$$PCC(\boldsymbol{a},\boldsymbol{b}) = \frac{cov(\boldsymbol{a},\boldsymbol{b})}{std(\boldsymbol{a}) \times std(\boldsymbol{b})}$$

$$PCC(\boldsymbol{a},\boldsymbol{b}) = \frac{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})(b_i - \mu_{\boldsymbol{b}})}{\sqrt{\sum_{i=1}^{n}(a_i - \mu_{\boldsymbol{a}})^2}\sqrt{\sum_{i=1}^{n}(b_i - \mu_{\boldsymbol{b}})^2}}$$

$$PCC(\boldsymbol{a},\boldsymbol{b}) = \frac{n\sum_{i=1}^{n} a_i b_i - (\sum_{i=1}^{n} a_i)(\sum_{i=1}^{n} b_i)}{\sqrt{n\sum_{i=1}^{n} a_i^2 - \left(\sum_{i=1}^{n} a_i\right)^2}\sqrt{n\sum_{i=1}^{n} b_i^2 - \left(\sum_{i=1}^{n} b_i\right)^2}}$$

$$cov(\boldsymbol{a},\boldsymbol{b}) = \frac{\sum(a_i - \overline{\boldsymbol{a}})(b_i - \overline{\boldsymbol{b}})}{n} \qquad std(\boldsymbol{a}) = \sqrt{\frac{\sum(a_i - \overline{\boldsymbol{a}})^2}{n}} \qquad \mu_{\boldsymbol{a}} = \frac{1}{n}\sum a_i \qquad \mu_{\boldsymbol{b}} = \frac{1}{n}\sum b_i$$

[실습] 유사도 함수 구현

- 실수를 저장하는 동일한 크기의 두 리스트 **a**와 **b**가 주어질 때, **a**와 **b**의 유사도를 계산하는 함수를 구현하시오.
- 구현할 유사도 함수
  - ➢ 코사인 유사도 함수: `cosine_sim(a, b)`
  - ➢ 피어슨 상관 계수 함수: `pearson_corr(a, b)`
- 구현 요구 사항
  - ① 두 리스트 a와 b의 크기가 서로 다르면 오류 메시지 출력
  - ② 두 리스트에 실수가 아닌 문자가 포함되어 있으면 마찬가지로 오류 메시지
  - ③ 두 리스트의 유사도를 계산한 결과를 반환(return) 및 콘솔 화면상에 출력(print)하는 기능을 반드시 포함

[실습] 유사도 함수 구현

- 구현 후 실제 유사도 분석
  - ➢ 아래 주어진 6개의 벡터들에 대해서 가장 가까운 쌍(pair)이 무엇인지 자신이 구현한 코사인 유사도 함수와 피어슨 상관 계수 함수를 이용하여 확인하시오.
  - ➢ 지난 시간에 구현한 유클리드/맨하탄 거리 함수를 이용하여 가장 가까운 쌍이 무엇인지 확인한 후 그 결과를 앞의 결과와 비교하시오.
  - ➢ 아래 예제 이외의 다양한 리스트를 직접 생성한 후 상기 두 유사도 함수를 이용하여 유사도를 계산하고 그 결과를 각각 비교 설명하시오.

$$\overrightarrow{D_1} = [0.82, 0.66, 0.51, 0.35, 0.75, 0.52, 0.62, 0.57]$$
$$\overrightarrow{D_2} = [0.51, 0.21, 0.81, 0.31, 0.15, 0.41, 0.11, 0.21]$$
$$\overrightarrow{D_3} = [0.19, 0.74, 0.24, 0.91, 0.81, 0.42, 0.43, 0.43]$$
$$\overrightarrow{D_4} = [0.24, 0.82, 0.16, 0.85, 0.94, 0.53, 0.38, 0.55]$$
$$\overrightarrow{D_5} = [0.40, 0.73, 0.53, 0.25, 0.83, 0.85, 0.55, 0.12]$$
$$\overrightarrow{D_6} = [0.92, 0.24, 0.57, 0.57, 0.53, 0.97, 0.83, 0.77]$$

Q & A