텍스트 데이터의 표현

컴터는 2진수로 표현된 데이터만 인지하여 처리한다
- 인코딩 및 디코딩의 데이터 변환 필요함

- 인코딩 ? = 데이터를 이진수로 변환함 컴이 알게
- 디코딩 ? = 사람이 알 수 있도록 변환 = 복호화 라고도 함

데이터 = 의미 x 단순 원시 값
정보 = 데이터를 목적이나 의도에 따라 처리하고 분석 -> 데이터에 의미 부여
정보처리 = 데이터에서 정보 추출하는 과정

텍스트 데이터?
- 단어와 단어가 연결 -> 하나의 문장or글
- ai는 텍스트를 분석하여 의미를 파악한다

텍스트 분석 종류
- 분류, 클러스터링, 비교, 번역, 요약

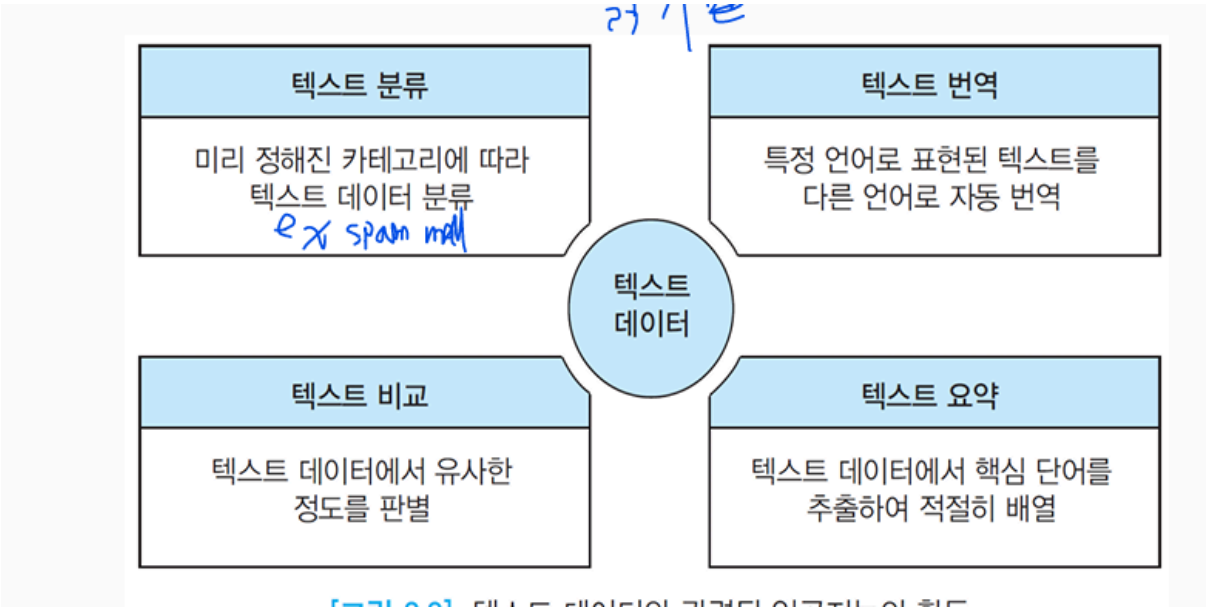


텍스트 데이터의 형태
- 정형 데이터 -> 정해진 형식과 기준에 따라 정리한 데이터
  연속형 데이터 -> 키, 몸무게-> 연속적인 값
  범주형 데이터 -> 성별, 출신학교 -> 동일한 특성 but 수치화 안됨

- 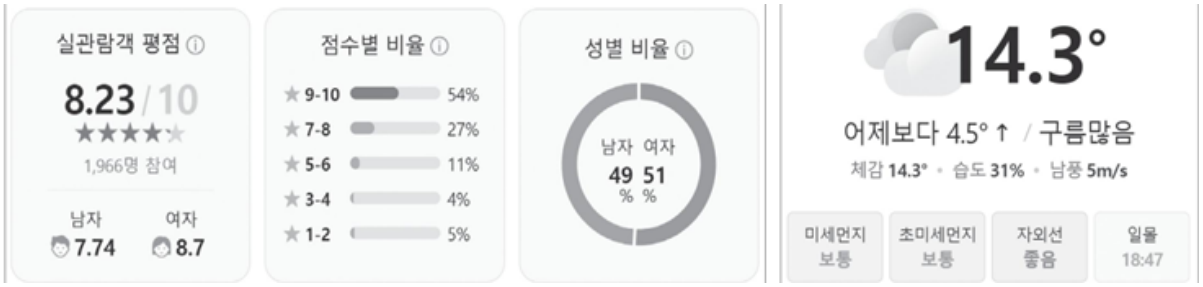

  비정형 데이터 -> 정형화x -> 컴이 인식x -> 정형데이터로 변환해야함
-

텍스트 데이터는 컴이 인식을 못해서, 단어 -> 수치화 필요함

집합을 이용한 텍스트 데이터의 수학적 표현

집합 ? = 명확한 조건을 만족하는 모임
근데 안명확하면 아님 ex) 키큰사람 모임, 맛있는 음식 모임
표현방법 -> 원소나열법 -> 집합 원소 일일이 나열하여 기호{}으로 나타낸 것
조건 제시법 -> 집합 규정하는데 조건 제시함

집합의 상등 -> 두 집합의 원소가 완전히 동일(순서 상관 x)
부분집합 -> A집합의 모든 원소가 B의 집합의 원소가 됨 -> A는 B의 부분집합
벤 다이어그램 -> 집합의 포함 관계를 폐곡선으로 표현한 그림

공집합 -> 원소가 하나도 없음 = 기호로는 {}으로 나타낼 수 있음, 어떤 집합A에 대해 항상 공집합은 그 집합의 부분집합 성립

| 연산 | 연산기호 | 연산방법 |
|---|---|---|
| 합집합 | $A \cup B$ | 집합 $A$와 집합 $B$의 모든 원소로 이루어진 집합 |
| 교집합 | $A \cap B$ | 집합 $A$와 집합 $B$의 공통 원소로 이루어진 집합 |
| 여집합 | $A^C$ | 전제 집합 $U$의 부분집합이 $A$일 때 $A$에 속하지 않는 원소로 이루어진 집합 |
| 차집합 | $A-B$ | 집합 $A$에는 속하지만 집합 $B$에는 속하지 않는 원소로 이루어진 집합 |

" $= A \setminus B$

- **[주의]** 두 집합의 차(Difference)는 실수에서의 뺄셈(Subtraction) 연산과는 의미가 다르며 집합 $A$에서 집합 $B$의 원소를 제외하는 것을 의미한다.

cf ✓

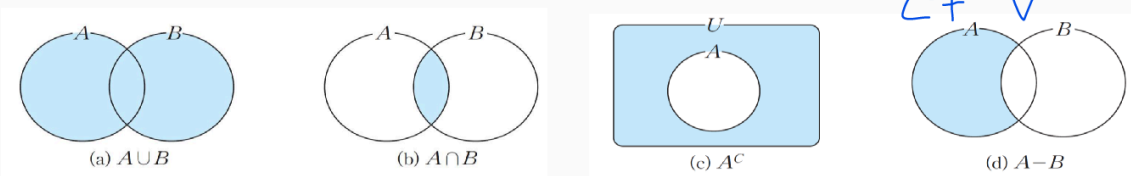


멱집합 P(a) : 집합 a의 모든 가능한 부분집합을 모아 놓은 집합 -> 당연히 공집합 포함

집합을 이용해 텍스트 표현하기

- ai는 텍스트데이터에서 핵심단어를 추출한 후 이들을 집합으로 이용한다\
  얘네는 단어의 의미를 직접적으로 이해x -> 고유한 수치를 부여하여 구분
  순서는 고려 안해서, 해당 텍스트 데이터가 가진 특징에 대한 정보는 알기 힘듦

벡터 = 크기 + 방향을 나타내는 물리량
벡터의 유향선분이 시작되고 끝나는 점 -> 벡터의 시점, 종점

위치벡터 -> 시점을 원점으로 하는 벡터
위치벡터의 성분 -> 종점의 좌표

시점이 $(a, b)$, 종점이 $(c, d)$인 평면벡터를 위치벡터로 변환하였을 때, 위치벡터의 성분을 구하라.

다음 그림에서 시점 $(a, b)$를 원점으로 이동하려면 $x$좌표를 $-a$, $y$좌표를 $-b$만큼 더해 주어야 하므로 종점 $(c, d)$는 $(c-a, d-b)$로 이동한다.

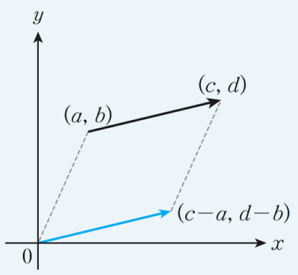


벡터의 크기 ||a|| 는 유향선분의 길이이다 ->

$$\boldsymbol{a} = (x_1, y_1) \rightarrow \ \|\boldsymbol{a}\| = \sqrt{x_1^2 + y_1^2}$$

$$\boldsymbol{a} = (x_1, y_1, z_1) \rightarrow \ \|\boldsymbol{a}\| = \sqrt{x_1^2 + y_1^2 + z_1^2}$$

단위벡터 : 길이가 1인 벡터

핵심 단어의 포함 여부를 나타내는 벡터

- 각 문서에 포함된 단어는 1, 아니면 0

기사 A

온라인 면접을 위해서는 지원서와 함께 컴퓨터에 지원자의 얼굴과 음성을 등록해야 한다.

기사 B

지원자의 얼굴과 음성은 다시 등록할 수 있으며, 등록이 끝나면 컴퓨터에서 면접 질문이 시작된다.

↓ 전체 핵심 단어들의 집합 구성

$A$={온라인, 면접, 지원서, 컴퓨터, 지원자, 얼굴, 음성, 등록}

$B$={지원자, 얼굴, 음성, 등록, 컴퓨터, 면접, 질문, 시작}

온라인

| 핵심 단어 | 온라인 | 면접 | 지원서 | 컴퓨터 | 지원자 | 얼굴 | 음성 | 등록 | 질문 | 시작 |
|---|---|---|---|---|---|---|---|---|---|---|
| 기사 A | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 0 | 0 |
| 기사 B | 0 | 1 | 0 | 1 | 1 | 1 | 1 | 1 | 1 | 1 |

장점 : 직관적 = 쉽다

단점 : 문서 내의 단어의 중요도를 판단하기 어렵다

위의 표에서 기사 A와 B에 포함된 핵심 단어들은 10개이므로 두 기사를 10차원 벡터를 이용하여 각각 다음과 같이 표현할 수 있다. 딕셔너리

기사 A : $\boldsymbol{a}=(1, 1, 1, 1, 1, 1, 1, 1, 0, 0)$

기사 B : $\boldsymbol{b}=(0, 1, 0, 1, 1, 1, 1, 1, 1, 1)$

-

핵심 단어의 빈도수를 표현하는 벡터

- 어떤 핵심 단어가 여러번 중복되면 중요도 높을 가능성
- 각 단어의 빈도수 계산

**예제 2.7**

주어진 표는 조리법 A와 B에 사용되는 핵심 단어의 빈도수를 나타낸 것이다. 다음 물음에 답하라.

| 핵심 단어 | 소고기 | 돼지고기 | 두부 | 파 | 김치 | 감자 | 고추장 |
|---|---|---|---|---|---|---|---|
| 조리법 A | 2 | 3 | 1 | 4 | 5 | 0 | 3 |
| 조리법 B | 3 | 1 | 2 | 3 | 0 | 0 | 1 |

(1) 각 조리법에서 가장 많이 사용되는 핵심 단어를 찾아라.

(2) 각 조리법에서 빈도수 벡터 $\boldsymbol{a}$와 $\boldsymbol{b}$를 각각 구하라.

**풀이**

(1) 조리법 A에서는 김치의 빈도수가 5로 가장 큰 값이므로 김치가 가장 많이 사용되는 핵심 단어이다.

조리법 B에서는 소고기와 파의 빈도수가 각각 3으로 가장 큰 값이므로 소고기와 파가 가장 많이 사용되는 핵심 단어이다.

(2) 조리법 A와 B에 해당되는 빈도수 벡터를 각각 $\boldsymbol{a}$와 $\boldsymbol{b}$라고 하면 다음과 같이 7차원 벡터로 나타낼 수 있다.

$$\boldsymbol{a}=(2, 3, 1, 4, 5, 0, 3)$$
$$\boldsymbol{b}=(3, 1, 2, 3, 0, 0, 1)$$

-

원 핫 벡터 : 하나의 성분만 1,나머진 싹 다 0

( 0,0,0,0,1,0,0)

해당 단어와 관련된 성분만 1, 아니면 0

기사 A : 코로나 바이러스 감염증

기사 B : 코로나 바이러스 백신 접종시기는?

기사 C : 코로나 팬데믹은 언제 종료될 것인가?

**핵심 단어들의 전체집합:**

$P$ ={코로나, 바이러스, 감염증, 백신, 접종시기, 팬데믹, 언제, 종료}

p = 딕셔너리

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| 0 or 1 | 0 or 1 | 0 or 1 | 0 or 1 | 0 or 1 | 0 or 1 | 0 or 1 | 0 or 1 |

원 핫 벡터로는 단어간 유사도 파악 x

- 또한, 원-핫 벡터 표현으로는 **단어 간의 유사도를 나타낼 수 없다.** 단점

**(e.g.,) $P$ = {늑대, 호랑이, 강아지, 고양이}**

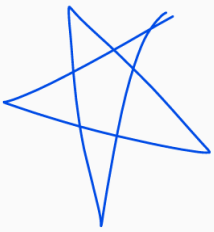

늑 대: $\boldsymbol{a} = (1,0,0,0)$ 강아지: $\boldsymbol{c} = (0,0,1,0)$

호랑이: $\boldsymbol{b} = (0,1,0,0)$ 고양이: $\boldsymbol{d} = (0,0,0,1)$

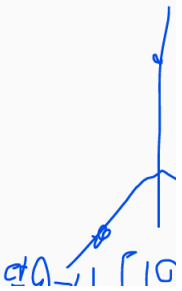

어떤 텍스트 데이터에서 전체 핵심 단어들을 모아 놓은 집합 $A$가 다음과 같다고 할 때, 권율과 을지문덕에 대한 원-핫 벡터를 구하라.

$$A=\{\text{이순신, 강감찬, 권율, 계백, 을지문덕}\}$$

집합 $A$에서 원소의 개수가 5이므로 5차원 원-핫 벡터로 각각의 핵심 단어를 표현할 수 있다. 권율과 을지문덕에 대한 원-핫 벡터를 각각 $\boldsymbol{a}$와 $\boldsymbol{b}$라고 가정하면 다음과 같다.

$$\boldsymbol{a}=(0, 0, 1, 0, 0)$$
$$\boldsymbol{b}=(0, 0, 0, 0, 1)$$

택스트 문서를 벡터로 나타내는법 : 1) 단어 각각의 등장 여부

2) 단어 각각의 등장 횟수 -> 둘다 문서를 표현한 벡터

3) 원 핫 인코딩 벡터 -> 각 단어를 표현하는 벡터 = 단어 자체를 의미