

다중 선형 회귀분석

(Multiple Linear Regression)

김성영교수
국립금오공과대학교
컴퓨터공학부

학습 내용

- 다중 선형 회귀가 무엇인지 설명할 수 있다.

다중 선형 회귀multiple linear regression

- 추가적인 정보를 사용하여 조금 더 정확한 예측 가능
- 2개 이상의 독립 변수 사용

Training data with multi-variable/feature

공부 시간(x_1)	결석일(x_2)	과목 점수(y)
9	5	59
30	2	90
17	3	75
2	1	50
40	0	95
35	10	72

m : number of features n : number of samples

$x^{(k)}$: input features of k^{th} training data

$x_j^{(k)}$: a value of input feature j in k^{th} training data

Hypothesis for multiple linear regression

$$H(\mathbf{x}) = \mathbf{w}\mathbf{x} + b$$

$$H(x_1, x_2) = w_1x_1 + w_2x_2 + b$$

$$\text{loss}(H(x_1, x_2), y) = \left(H(x_1^{(k)}, x_2^{(k)}) - y^{(k)} \right)^2$$

$$J(w_1, w_2, b) = \frac{1}{n} \sum_{k=1}^n \left(H(x_1^{(k)}, x_2^{(k)}) - y^{(k)} \right)^2$$

벡터를 사용한 표현 단순화 (1)

$$H(x_1, x_2, x_3) = w_1x_1 + w_2x_2 + w_3x_3 + b$$

b 생략

$$H(x_1, x_2, x_3) = w_1x_1 + w_2x_2 + w_3x_3$$

$$\begin{pmatrix} w_1 & w_2 & w_3 \end{pmatrix} \cdot \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = w_1x_1 + w_2x_2 + w_3x_3$$

W **X**

$$H(\mathbf{x}) = \mathbf{wx}$$

벡터를 사용한 표현 단순화 (2)

$$H(x_1, x_2, x_3) = w_1x_1 + w_2x_2 + w_3x_3 + b \text{ 경우}$$

$$\begin{pmatrix} b & w_1 & w_2 & w_3 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix} = b + w_1x_1 + w_2x_2 + w_3x_3$$

feature augmentation
(bias augmentation: 상수항 결합)

W

X

$$H(\mathbf{x}) = \mathbf{W}\mathbf{x}$$

벡터를 사용한 표현 단순화 (3)

$$H(x_1, x_2, x_3) = w_1x_1 + w_2x_2 + w_3x_3 + b \text{ 경우}$$

$$(b \quad w_1 \quad w_2 \quad w_3) \cdot \begin{pmatrix} 1 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix} = b + w_1x_1 + w_2x_2 + w_3x_3$$

$\mathbf{w}^T$ $\mathbf{x}$

$$H(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$$

행렬을 사용한 표현 단순화

$$H(x_1, x_2, x_3) = w_1x_1 + w_2x_2 + w_3x_3 + b \text{ 경우}$$

$$(b \quad w_1 \quad w_2 \quad w_3) \cdot \begin{pmatrix} 1 \\ x_1 \\ x_2 \\ x_3 \end{pmatrix} = b + w_1x_1 + w_2x_2 + w_3x_3$$

$\mathbf{w}^T$ $\mathbf{X}$

예를 들어, 100개 샘플이 있으면
(4x100) 크기의 입력 행렬(X) 사용

$$H(X) = \mathbf{w}^T X$$

$$H(X) = X^T \mathbf{w}$$

샘플이 행단위로
존재하는 경우 (100x4)

Gradient descent

Hypothesis: $H(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$

Parameters: $w_0, w_1, \dots, w_m(\mathbf{w})$

Cost function: $J(\mathbf{w}) = \frac{1}{2n} \sum_{k=1}^n (H(x^{(k)}) - y^{(k)})^2$

Gradient descent:



$$\mathbf{w}^{(t+1)} := \mathbf{w}^{(t)} - \alpha \frac{\partial}{\partial w_k} J(\mathbf{w})$$

for $k = 0, 1, 2, \dots, m$

예제: 공부와 과외 횟수에 따른 성적 추정

- 학습 데이터(training data)

공부한 시간(x_1)	2	4	6	8
과외 수업 횟수(x_2)	0	4	2	3
성적(y)	81	93	91	97



예제: 공부와 과외 횟수에 따른 성적 추정

- 소스코드

013_01_Gradient Descent Method1.ipynb

소스코드

- 013_02_dataset_generator_test1.ipynb
- 013_03_Gradient_descent_Method2.ipynb

참고: make_regression() (1)

- Scikit-learn의 datasets 서브 패키지에 존재
- 회귀분석용 가상 데이터 생성 ($y = \mathbf{w}^t \mathbf{x} + b + \epsilon$)
- 입력 인자
 - n_samples: 표본 데이터(샘플)의 개수 (정수, 옵션 ~ 디폴트 100)
 - n_features: 독립 변수(feature)의 차원 (정수, 옵션 ~ 디폴트 100)
 - n_targets: 종속 변수(target)의 차원 (정수, 옵션 ~ 디폴트 1)
 - bias: y 절편, (실수, 옵션 ~ 디폴트 0.0)
 - noise: 잡음(종속 변수에 더함) (실수, 옵션 ~ 디폴트 0.0)
 - coef: 모델 파라미터 출력 여부 (논리값, 옵션 ~ 디폴트 False)
 - random_state: 난수 발생용 시드 (정수, 옵션 ~ 디폴트 None)

참고: make_regression() (2)

- 출력 인자

- x : 독립 변수의 표본 데이터 행렬 x

- $(n_samples, n_features)$ 크기의 2차원 배열

- y : 종속 변수의 표본 데이터 벡터 y

- $n_samples$ 크기의 1차원 배열 또는 $(n_samples, n_targets)$ 크기의 2차원 배열

- $coef$: 선형 모델의 파라미터 w

- $n_features$ 크기의 1차원 배열 또는 $(n_features, n_targets)$ 크기의 2차원 배열

참고자료

- 모두의 딥러닝, 조태호 지음, 길벗
- 케라스 창시자에게 배우는 딥러닝, 프랑소와 솔레, 길벗
- 모두를 위한 머신러닝/딥러닝 (홍콩과기대 김성훈교수)
 - <http://hunkim.github.io/ml/>
- Stanford Machine Learning
 - <http://www.holehouse.org/mlclass/>
- Machine Learning (한성대 지준교수)
 - <http://jun.hansung.ac.kr/ml>
- 수학적으로 접근하는 딥러닝 올인원 패키지, 신경식, 패스트 캠퍼스 신경식